


Makine Öğrenmesi

Ders 8



Bu Dersin İçeriği

I. Veri kümeleri

a) Veri setini bölme

II. Genelleştirme

III. Aşırı Öğrenme-Uyum (Overfitting)

a) Model Karmaşıklığı

b) L_2 Düzenlemesi

IV. Kayıp Eğrilerini Yorumlama

I. Veri Kümeleri: Veri Setini Bölme

1. Tüm iyi yazılım mühendisliği projeleri, uygulamalarını test etmek için önemli miktarda mesai harcar.
2. Benzer şekilde, tahminlerinin doğruluğunu belirlemek ve iyileştirmek için makine öğrenimi modelimizi test etmemiz gerekir.
3. Öğrenme modelimizi, modeli eğitmek için kullanılanlardan farklı bir örnek kümesine karşı test etmeliyiz.
4. Farklı örnekler üzerinde test yapmak, modelimizin uygunluğunun aynı örnek kümesi üzerinde test yapmaktan daha güçlü bir kanıttır.
5. Peki bu farklı örnekleri nereden buluruz?
6. Geleneksel olarak makine öğreniminde, bu farklı örnekleri orijinal veri kümemizi bölerek elde ederiz.

I. Veri Kümeleri: Veri Setini Bölme

1. Bu nedenle, orijinal veri kümesini iki alt kümeye ayırmamız gerektiğini varsayabiliriz;
 - a) Modelin eğitilmesi için kullanılan verileri içeren bir eğitim kümesi.
 - b) Eğitilen modelin değerlendirilmesi için kullanılan verileri içeren bir test kümesi.



I. Veri Kümeleri: Veri Setini Bölme

Başlamadan önce ön sezilerimizi kontrol edelim.

1. Diyelim ki eğitim setinde eğitim alıyoruz ve birden fazla turda test setinde değerlendirme yapıyoruz.
2. Her turda, hiper parametreleri ve özellik setini nasıl güncelleyeceğimize rehberlik etmek için test seti sonuçlarını kullanıyoruz. Bu yaklaşımda yanlış olan nedir?
 - a) Bu yaklaşım hesaplama açısından verimsizdir. Her test turundan sonra hiper parametreleri veya özellik setlerini değiştirmeliyiz. Bu da maliyeti arttırır.
 - b) Bu yaklaşım iyidir. Sonuçta, eğitim setinde eğitim alıyoruz ve ayrı bir test setinde değerlendirme yapıyoruz.
 - c) Bu prosedürün birçok turunu yapmak, modelin test setinin özelliklerine örtük olarak uymasına neden olabilir.

I. Veri Kümeleri: Veri Setini Bölme

- a) Bu yaklaşım hesaplama açısından verimsizdir. Her test turundan sonra hiper parametreleri veya özellik setlerini değiştirmeliyiz.

Sık test yapmak pahalıdır ancak kritiktir. Ancak, sık test yapmak ek eğitimden çok daha az maliyetlidir. Hiper parametreleri ve özellik setini optimize etmek model kalitesini önemli ölçüde iyileştirebilir, bunun nasıl yapılacağı belirlenip, bu nedenle bunlar üzerinde çalışmak için her zaman bütçe zamanı ve hesaplama kaynakları ayırmamız gerektiğini bilmeliyiz.

I. Veri Kümeleri: Veri Setini Bölme

- b) Bu yaklaşım iyidir. Sonuçta, eğitim setinde eğitim alıyoruz ve ayrı bir test setinde değerlendirme yapıyoruz.**

Aslında burada ince bir konu var. Yavaş yavaş neyin ters gidebileceğini düşünelim.

Eğitim ve test verileri öncesinde sabit olarak ayrıldığı için değişmiyor. İyi örnekleri eğitim için ayırdıysak kötü örnekleri test seti için ayırmalıyız. Önemli olan test veri seti sonuçlarıdır.

I. Veri Kümeleri: Veri Setini Bölme

- c) Bu prosedürün birçok turunu yapmak, modelin test setinin özelliklerine örtük olarak uymasına neden olabilir.

Aynı test setini ne kadar sık kullanırsak, modelin test setine uyma olasılığı o kadar artar. Bir öğretmenin “teste göre öğretmesi” gibi, model istemeden test setine uyar ve bu da modelin gerçek dünya verilerine uymasını zorlaştırabilir.

I. Veri Kümeleri: Veri Setini Bölme

1. Veri setini iki kümeye bölmek iyi bir fikirdir, ancak daha iyi bir yaklaşım veri setini üç alt kümeye bölmektir.
2. Eğitim seti ve test setine ek olarak üçüncü bir alt küme daha oluşturmamız;
3. Doğrulama kümesi, model eğitilirken model üzerinde ilk testleri gerçekleştirir.




Veri kümesi-seti

4. Eğitim setinden elde edilen sonuçları değerlendirmek için doğrulama setini kullanılır.
5. Doğrulama setinin tekrar tekrar kullanılması modelimizin *iyi tahminler yaptığını gösterdikten sonra*, modelimizi iki kez kontrol etmek için test setini kullanılır.


I. Veri Kümeleri: Veri Setini Bölme

1. Aşağıdaki şekil bu iş akışını önermektedir.
2. Şekilde, "Modeli ince ayarlamak", öğrenme oranını değiştirmekten, özellik eklemeye veya çıkarmaya, sıfırdan tamamen yeni bir model tasarlamaya kadar modelle ilgili her şeyi ayarlamak anlamına gelir.



3. Eğitim setimizdeki bir özelliği dönüştürdüğümüzde, doğrulama setinde, test setinde ve gerçek dünya veri setinde aynı dönüşümü yapmamız gerektiğini unutmayalım.

I. Veri Kümeleri: Veri Setini Bölme



1. Eğitim ve test süreci için bu iş akışı şu anda en iyisidir, ancak bu iş akışıyla bile test kümeleri ve doğrulama kümeleri tekrarlanan kullanımla "yıpranır". (Yıpranmak?)
2. Yani, hiper parametre ayarları veya diğer model iyileştirmeleri hakkında kararlar almak için aynı verileri ne kadar çok kullanırsanız, modelin yeni veriler üzerinde iyi tahminler yapacağına olan güven o kadar azalır.
3. Bu nedenle, test kümesini ve doğrulama kümesini "yenilemek" için daha fazla veri toplamak iyi bir fikirdir. Yeniden başlamak harika bir sıfırlamadır.

I. Veri Kümeleri: Veri Setini Bölme

1. Yine önce ön sezilerimi kontrol edelim.
2. Veri setindeki tüm örnekleri karıştırdık ve karıştırılan örnekleri eğitim, doğrulama ve test setlerine böldük.
3. Ancak, test setinizdeki kayıp değeri o kadar şaşırtıcı derecede düşük ki bir hatadan şüphelenebiliriz.
4. Ne yanlış gitmiş olabilir?
 - a) Şans eseri, test seti modelin iyi performans gösterdiği örnekleri içeriyordur.
 - b) Eğitim ve test gerekirci değildir (non-deterministic). Bazen, şans eseri, test kaybınız inanılmaz derecede düşüktür. Sonucu doğrulamak için testi tekrar tekrar çalıştırmamız gerekir
 - c) Test setindeki örneklerin çoğu, eğitim setindeki örneklerin kopyalarıdır.

I. Veri Kümeleri: Veri Setini Bölme

1. Ne yanlış gitmiş olabilir?

a) Şans eseri, test seti modelin iyi performans gösterdiği örnekleri içeriyordur.

Örnekler iyi karıştırdık bu nedenle bu mümkün değildir.

b) Eğitim ve test gerekirci değildir (non-deterministic). Bazen, şans eseri, test kaybınız inanılmaz derecede düşüktür. Sonucu doğrulamak için testi tekrar tekrar çalıştırmamız gerekir

Kayıp her çalıştırmada biraz değişse de, sıra dışı düşünecek kadar değişmez.

c) Test setindeki örneklerin çoğu, eğitim setindeki örneklerin kopyalarıdır.

Bu olasıdır. Çünkü bu durum çok sayıda gereksiz örneğin bulunduğu bir veri setinde sorun olabilir. Testten önce test setinden yinelenen örneklerin silinmesi tavsiye edilir.

I. Veri Kümeleri: Veri Setini Bölme

1. Test kümeleriyle ilgili ek sorunlar
2. Önceki sorunun da gösterdiği gibi, yinelenen örnekler model değerlendirmesini etkileyebilir.
3. Bir veri kümesini eğitim, doğrulama ve test kümelerine böldükten sonra, eğitim kümesindeki örneklerin yinelenenleri olan doğrulama kümesindeki veya test kümesindeki tüm örnekleri silmemiz gerekir.
4. Bir modelin tek adil testi yinelenenlere değil, yeni örnekler kullanılarak yapılır.

I. Veri Kümeleri: Veri Setini Bölme

- 1. Örneğin, konu bilgisi, e-posta gövdesini ve gönderenin e-posta adresini özellik olarak kullanarak bir e-postanın spam olup olmadığını tahmin eden bir modeli ele alalım.**
- 2. Verileri %80-20'lik bir bölünmeyle eğitim ve test kümelerine böldüğümüzü varsayalım.**
- 3. Eğitimden sonra, model hem eğitim kümesinde hem de test kümesinde %99 hassasiyete ulaşır.**
- 4. Muhtemelen test kümesinde daha düşük bir hassasiyet beklenir, bu nedenle verilere tekrar bakıldığında ve test kümesindeki örneklerin çoğunun eğitim kümesindeki örneklerin yinelenenleri olduğunu keşfedilebilir. (Sıklıkla)**
- 5. Sorun şudur, verileri bölmeden önce giriş veri kümemizde aynı spam e-postası için yinelenen girişleri temizlemeyi ihmal etmemizdir.**
- 6. Bu, test verilerimizin bir kısmı üzerinde yanlışlıkla eğitim yapıldığını gösterir.**

I. Veri Kümeleri: Veri Setini Bölme

1. Özetle, iyi bir test seti veya doğrulama seti için aşağıdaki kriterler kontrol edilmelidir:
 - a) İstatistiksel olarak anlamlı test sonuçları elde etmek için yeterince büyük olmalı,
 - b) Bir bütün olarak veri setini temsil etmeli. (Homojen)
 - c) Başka bir deyişle, eğitim setinden farklı özelliklere sahip bir test seti seçilmemeli.
 - d) Modelin iş amacının bir parçası olarak karşılaşıacağı gerçek dünya verilerini temsil etmeli.
 - e) Eğitim setinde yinelenen sıfır örnek olmalı

II. Genelleştirme


1. Bir modeli eğittiğimizde aslında onu verinin belirli (spesifik) bir kümesinde eğitiriz.
2. Verilerin belirli bir kümesi aslında her zamana gerçek dünya verilerinin bir alt kümesi olmuştur.
3. Eğer model eğitim seti üzerinde yüksek başarımlı tahminler yapabilirken, buna karşılık yepyeni yeni veriler üzerinde düşük başarımlı tahminler yaparsa bu durum modelin genelleştirilmediğini gösterir.
4. Buna modelin eğitim verisi üzerinde aşırı öğrenme-uyum (overfit) sağlaması denir.
5. Belirli kalıplara o kadar yakın bir şekilde ayarlanmıştır ki zaten gördüğü verilerden yepyeni kalıpları belirleyemez durumdadır.

III. Aşırı Uyum

1. Aşırı uyum eğitim verileriyle modelin yeni veriler üzerinde doğru tahminler yapamayacağı kadar yakından eşleşen bir model oluşturmak anlamına gelir.
2. Aşırı uyum, eğitim setiyle o kadar yakından eşleşen (ezberleyen) bir model oluşturmak anlamına gelir ki model yeni veriler üzerinde doğru tahminler yapamaz.
3. Aşırı uyum sağlayan bir model, laboratuvarı iyi performans gösteren ancak gerçek dünyada değersiz olan bir icada benzer. Aşırı uyum, akademik bir varsayım değil, makine öğrenmesinde yaygın bir sorundur.
4. Aşırı uyum, sadece en sevdiğiniz öğretmenin tavsiyelerine sıkı sıkıya uymaya benzer. Muhtemelen o öğretmenin dersinde başarılı olursunuz, ancak o öğretmenin fikirlerine “aşırı uyum” sağlayabilir ve diğer derslerde başarısız olabilirsiniz. Farklı öğretmenlerin tavsiyelerine uymak, yeni durumlara daha iyi adapte olmanızı sağlayacaktır.
5. Düzenli hale getirme (Regularization) aşırı uyumu azaltabilir. Büyük ve çeşitli bir eğitim seti üzerinde eğitim yapmak da aşırı uyumu azaltabilir.

III. Aşırı Uyum


1. Aşağıdaki şekilde her geometrik şeklin kare bir ormandaki bir ağacın konumunu temsil ettiğini düşünelim.
2. Mavi elmaslar sağlıklı ağaçların yerlerini, turuncu daireler ise hasta ağaçların yerlerini işaretler.
3. Sağlıklı ağaçları hasta ağaçlardan ayırmak için zihninizde herhangi bir şekil çizelim.



Eğitim seti: kare ormandaki sağlıklı ve hasta ağaçların yerleri.

III. Aşırı Uyum

Basit bir çizimle
ilk deneme
fena değil



Modelin sağlıklı ağaçları kendi bölgesinde tahmin ettiği alan

Modelin hasta ağaçları kendi bölgesinde tahmin ettiği alan

◆ Sağlıklı olup hasta olarak tahmin edilen ağaç

⊕ Hasta olup sağlıklı tahmin edilen ağaç


◆ Sağlıklı ağaç

○ Hasta ağaç

Eğitim seti: kare ormandaki sağlıklı ve hasta ağaçların yerleri.

III. Aşırı Uyum

Daha iyi bir
çizimle
biraz daha iyi



Modelin sağlıklı ağaçları kendi bölgesinde tahmin ettiği malan

Modelin hasta ağaçları kendi bölgesinde tahmin ettiği malan

◆ Sağlıklı olup hasta olarak tahmin edilen ağaç

⊕ Hasta olup sağlıklı tahmin edilen ağaç


◆ Sağlıklı ağaç

○ Hasta ağaç

Eğitim seti: kare ormandaki sağlıklı ve hasta
ağaçların yerleri.

III. Aşırı Uyum

Daha karmaşık bir çizimle oldukça iyi bir ayırım



Eğitim seti: kare ormandaki sağlıklı ve hasta ağaçların yerleri.

Modelin sağlıklı ağaçları kendi bölgesinde tahmin ettiği malan

Modelin hasta ağaçları kendi bölgesinde tahmin ettiği malan

◆ Sağlıklı olup hasta olarak tahmin edilen ağaç


⊕ Hasta olup sağlıklı tahmin edilen ağaç

◆ Sağlıklı ağaç

○ Hasta ağaç

III. Aşırı Uyum

1. Aşağıdaki gösterilen karmaşık şekiller, ağaçların biri hariç hepsini başarıyla kategorize etti.
2. Şekilleri bir model olarak düşünürsek, bu harika bir model oluşturduğumuzu düşünebiliriz.



Modelin sağlıklı ağaçları kendi bölgesinde tahmin ettiği malan

Modelin hasta ağaçları kendi bölgesinde tahmin ettiği malan

◆ Sağlıklı olup hasta olarak tahmin edilen ağaç


⊕ Hasta olup sağlıklı tahmin edilen ağaç

◆ Sağlıklı ağaç

○ Hasta ağaç

III. Aşırı Uyum

1. Gerçekten de öyle mi?
2. Sadece gerçekten mükemmel olan bir model, yeni örnekleri başarıyla kategorize eder.
3. Aşağıdaki şekil, aynı modelin test setinden yeni örnekler üzerinde tahminlerde bulunduğu ne olduğunu gösterir.




Modelin sağlıklı ağaçları kendi bölgesinde tahmin ettiği malan

Modelin hasta ağaçları kendi bölgesinde tahmin ettiği malan

- ◆ Sağlıklı olup hasta olarak tahmin edilen ağaç
- ⊕ Hasta olup sağlıklı tahmin edilen ağaç
- ◆ Sağlıklı ağaç
- Hasta ağaç


III. Aşırı Uyum

1. Yani, aşağıdaki şekilde gösterilen karmaşık model eğitim setinde harika bir iş çıkardı ancak test setinde oldukça kötü bir iş çıkardı.
2. Bu, bir modelin eğitim seti verilerine aşırı uyum sağlamasının klasik bir örneğidir.




III. Aşırı Uyum

1. Uygunluk, aşırı uygunluk ve yetersiz uygunluk: Bir model yeni veriler üzerinde iyi tahminler yapmalıdır. Yani, yeni verilere “uyan” bir model oluşturmayı hedefliyoruz.
2. Gördüğümüz gibi, aşırı uyumlu bir model eğitim seti üzerinde mükemmel tahminler yapar ancak yeni veriler üzerinde zayıf tahminler yapar.
3. Uyumsuz bir model ise eğitim verileri üzerinde bile iyi tahminler yapamaz.
4. Aşırı uyumlu bir model laboratuvarı iyi performans gösteren ancak gerçek dünyada kötü performans gösteren bir ürüne benziyorsa, yetersiz uyumlu bir model laboratuvarı bile iyi performans göstermeyen bir ürüne benzer.




III. Aşırı Uyum

1. Genelleme, aşırı uyumun tam tersidir.
2. Yani, iyi genelleme yapan bir model yeni verilerde iyi tahminler yapar.
3. Amacımız, yeni verilere iyi genelleme yapan bir model oluşturmak olmalıdır.
4. Aşırı uyumun tespit edilmesi: Aşağıdaki eğriler aşırı uyumu tespit etmenize yardımcı olur:
 - a) kayıp eğrileri (loss curve)
 - b) genelleme eğrileri (generalization curve)




III. Aşırı Uyum

1. Bir kayıp eğrisi, bir modelin kaybını eğitim yinelemelerinin sayısına göre çizer.
2. İki veya daha fazla kayıp eğrisi gösteren bir grafiğe genelleme eğrisi denir.
3. Aşağıdaki genelleme eğrisi iki kayıp eğrisini gösterir:



III. Aşırı Uyum

1. Bu eğri aşırı uyumu güçlü bir şekilde ima eden bir genelleleme eğrisidir.
2. İki kayıp eğrisinin ilk başta benzer davrandığını ve sonra farklılaştığını fark edebiliriz.
3. Yani, belirli sayıda yinelemeden sonra, eğitim seti için kayıp azalır veya sabit kalır (yakınsar), ancak doğrulama seti için artar. Bu, aşırı uyumu gösterir.
4. Buna karşılık, iyi uyum sağlayan bir model için bir genelleleme eğrisi, benzer şekillere sahip iki kayıp eğrisi göstermelidir.



III. Aşırı Uyum

1. Çok genel olarak, aşırı uyum aşağıdaki sorunlardan birinden veya her ikisinden kaynaklanır:
 - a) Eğitim seti gerçek yaşam verilerini (veya doğrulama setini veya test setini) yeterince temsil etmiyor.
 - b) Model çok karmaşık.
2. Genelleme koşulları: Bir model bir eğitim seti üzerinde eğitilir, ancak bir modelin değerinin gerçek testi, yeni örnekler, özellikle de gerçek dünya verileri üzerinde ne kadar iyi tahminler yaptığıdır.
3. Bir model geliştirirken, test setiniz gerçek dünya verileri için bir vekil görevi görür.


III. Aşırı Uyum

1. İyi genelleme yapan bir modelin eğitilmesi aşağıdaki veri kümesi koşullarını gerektirir:
 - a) Örnekler bağımsız ve aynı şekilde dağılmış olmalıdır (independently and identically distributed-i.i.d).

i.i.d: Değişmeyen bir dağılımdan çekilen ve çizilen her değer daha önce çizilen değerlere bağlı olmadığı veriler. Bir i.i.d. makine öğreniminin ideal gazıdır (bkz: ideal gaz); kullanışlı bir matematiksel yapıdır ancak gerçek dünyada neredeyse hiç bulunmaz. Örneğin, bir web sayfasını ziyaret edenlerin dağılımı kısa bir zaman aralığında i.i.d. olabilir; yani, dağılım o kısa zaman aralığında değişmez ve bir kişinin ziyareti genellikle bir diğerinin ziyaretinden bağımsızdır. Ancak, bu zaman aralığını genişletirseniz, web sayfasının ziyaretçilerinde mevsimsel farklılıklar ortaya çıkabilir.
 - b) Veri kümesi sabittir, yani veri kümesi zaman içinde önemli ölçüde değişmez.
 - c) Veri kümesi bölümleri aynı dağılıma sahiptir. Yani, eğitim kümesindeki örnekler doğrulama kümesindeki, test kümesindeki ve gerçek dünya verilerindeki örneklerle istatistiksel olarak benzerdir. Aşağıdaki alıştırmalar aracılığıyla önceki koşulları keşfedin.

III. Aşırı Uyum: Model Karmaşıklığı

1. Sağlıklı ağaçları tespit eden test setindeki birçok ağacı yanlış kategorilendiren modelimizi hatırlayalım;
2. Önceki model birçok karmaşık şekil içerir. Daha basit bir model yeni verileri daha iyi işler mi?
3. Karmaşık modeli gülünç derecede basit bir modelle, düz bir çizgiyle değiştirdiğimizi varsayalım.




Modelin sağlıklı ağaçları kendi bölgesinde tahmin ettiği malan

Modelin hasta ağaçları kendi bölgesinde tahmin ettiği malan

- ◆ Sağlıklı olup hasta olarak tahmin edilen ağaç
- ⊕ Hasta olup sağlıklı tahmin edilen ağaç
- ◆ Sağlıklı ağaç
- Hasta ağaç

III. Aşırı Uyum: Model Karmaşıklığı

1. Basit model, yeni verilerde karmaşık modelden daha iyi genelleme yapar.
2. Yani, basit model test kümesinde karmaşık modelden daha iyi tahminlerde bulunmuştur.



III. Aşırı Uyum: Model Karmaşıklığı


1. Basitlik uzun zamandır karmaşıklığı yenmektedir.
2. Aslında, basitliğe olan tercih antik Yunan'a kadar uzanır.
3. Yüzyıllar sonra, Occam'lı William adlı on dördüncü yüzyıl rahibi, Occam'ın usturası olarak bilinen bir felsefede basitliğe olan tercihi resmileştirdi.
4. Bu basitlik veya tutumluluk yasası olarak da bilinir.
5. Bu felsefe, makine öğrenimi de dahil olmak üzere birçok bilimin temel ilkesi olmaya devam etmektedir.
6. "olasılıklar zorunluluk olmadan çoğaltılmamalıdır" ilkesine dayanan problem çözme yaklaşımı.
7. "En basit açıklama büyük olasılıkla doğru olandır" ifadesine benzer biçimde çeşitli şekillerde yorumlanmıştır.



Ockhamlı William'ın el yazması çizimi

III. Aşırı Uyum: Model Karmaşıklığı

1. Bu felsefi ustura, aynı tahminle ilgili rakip hipotezler sunulduğunda ve her iki hipotez de eşit açıklayıcı güce sahip olduğunda, en az varsayım gerektiren hipotezin tercih edilmesi gerektiğini ve bunun farklı tahminlerde bulunan hipotezler arasında seçim yapmanın bir yolu olmadığını savunur.
2. Benzer şekilde, bilimde Occam'ın usturası, aday modeller arasında kesin bir hakem olmaktan ziyade teorik modellerin geliştirilmesinde tümevarımsal bir sezgisel yöntem olarak kullanılır.



3. Basitleştirmenin de zor olabileceğini unutmayalım.

III. Aşırı Uyum: Düzenleme

1. Makine öğrenimi modelleri birbiriyle çelişen iki hedefi aynı anda karşılamalıdır:
 - a) Verilere iyi uyum sağlama.
 - b) Verilere mümkün olduğunca basit bir şekilde uyum sağlama.
2. Bir modeli basit tutmaya yönelik yaklaşımlardan biri karmaşık modelleri cezalandırmaktır; yani eğitim sırasında modeli daha basit olmaya zorlamaktır.
3. Karmaşık modellerin cezalandırılması (penalizing), düzenlemenin bir biçimi şeklinde tanımlanır.
4. Düzenleme benzetmesi için şu örneği verebiliriz.

III. Aşırı Uyum: Düzenleme

- 1. Düzenleme benzetmesi için şu örneği verebiliriz;**
- 2. Bir derste sınıftaki her öğrencinin, öğretmeni rahatsız eden bir ses çıkaran küçük bir zili olduğunu varsayalım.**
- 3. Öğretmen dersi çok karmaşık anlattığında öğrenciler zile basıyor olsunlar.**
- 4. Zil seslerine sinirlenen öğretmen dersi basitleştirmek zorunda kalsın.**
- 5. Öğretmen, “Basitleştirdiğimde yeterince açık olamıyorum” diye şikayet edebilir.**
- 6. Öğrenciler de “Tek amaç benim anlayabileceğim kadar basit bir şekilde anlatmak” diye karşılık verebilir.**
- 7. Yavaş yavaş, zil sesleri öğretmeni, yeterince kesin olmasa bile, uygun şekilde daha basit bir ders vermeye yönelik eğitecektir.**

III. Aşırı Uyum: Düzenleme

1. Kayıp ve Karmaşıklık: Şimdiye kadar eğitim sürecinde tek amacın kaybı en aza indirmek olduğunu öne sürdük; yani amaç şuydu,

$$\text{minimize } (loss)$$

2. Gördüğümüz gibi, *yalnızca kaybı en aza indirmeye odaklanan modeller* aşırı uyum sağlama eğilimindedir.
3. Daha iyi bir eğitim optimizasyon algoritması, kayıp ve karmaşıklığın bir kombinasyonunu en aza indirir:

$$\text{minimize } (loss + complexity)$$

4. Buna karşılık kayıp ve karmaşıklık tipik olarak ters orantılıdır.
5. Karmaşıklık arttıkça kayıp azalır. Karmaşıklık azaldıkça kayıp artar.
6. Modelin hem eğitim verileri hem de gerçek dünya verileri üzerinde iyi tahminler yaptığı makul bir orta yol bulmamız gerekir.
7. Yani, modelimiz kayıp ve karmaşıklık arasında makul bir uzlaşma bulmalıdır.

III. Aşırı Uyum: Düzenleme

- 1. Karmaşıklık nedir?**
- 2. Kaybı ölçmenin birkaç farklı yolunu görmüştük peki karmaşıklığı nasıl ölçeriz?**
- 3. Yine sezgilerimizle bir yol bulmaya çalışalım;**
- 4. Aşağıdaki fikirlerden hangisinin makul karmaşıklık ölçütleri olacağı düşünülebilir?**
 - a) Karmaşıklık, modeldeki tüm özelliklerin önyargılarının bir fonksiyonudur.**
 - b) Karmaşıklık, modelin ağırlıklarının bir fonksiyonudur.**
 - c) Karmaşıklık, modelin ağırlıklarının karesinin bir fonksiyonudur.**

III. Aşırı Uyum: Düzenleme

1. Karmaşıklık nedir?
2. Kaybı ölçmenin birkaç farklı yolunu görmüştük peki karmaşıklığı nasıl ölçeriz?
3. Yine sezgilerimizle bir yol bulmaya çalışalım;
4. Aşağıdaki fikirlerden hangisinin makul karmaşıklık ölçütleri olacağı düşünülebilir?
 - a) Karmaşıklık, modeldeki tüm özelliklerin önyargılarının bir fonksiyonudur: Önyargı karmaşıklığı ölçmez.
 - b) Karmaşıklık, modelin ağırlıklarının bir fonksiyonudur: Bazı modellerin karmaşıklığını ölçmenin bir yoludur. Bu metriğe L_1 düzenlemesi denir.
 - c) Karmaşıklık, modelin ağırlıklarının karesinin bir fonksiyonudur: Bazı modellerin karmaşıklığını bu şekilde ölçebiliriz. Bu metriğe L_2 düzenlemesi denir.

III. Aşırı Uyum: L_2 Düzenlemesi

1. Karmaşıklığı ölçen L_2 düzenlemesi, aşağıdaki formülü kullanan popüler bir düzenleme ölçütüdür;

$$L_2 = w_1^2 + w_2^2 + w_3^2 \dots \dots w_n^2$$

2. Örneğin, aşağıdaki tablo altı ağırlığa sahip bir model için L_2 düzenlemesinin hesaplanmasını göstermektedir:

	Değer	Karesi
w_1	0,1	0,01
w_2	-0,6	0,36
w_3	5	25
w_4	-1,1	1,21
w_5	0,35	0,1225
w_6	-0,2	0,04
		26,7425

III. Aşırı Uyum: L_2 Düzenlemesi

1. Sıfıra yakın ağırlıkların L_2 düzenlemesini çok fazla etkilemediğini, ancak büyük ağırlıkların büyük bir etkiye sahip olabileceğini görülmektedir.
2. Örneğin, önceki hesaplamada: Tek bir ağırlık (w_3) toplam karmaşıklığın yaklaşık %93'üne katkıda bulunur.
3. Diğer beş ağırlık toplu olarak toplam karmaşıklığın yalnızca yaklaşık %7'sine katkıda bulunur.
4. L_2 düzenlemesi ağırlıkları 0'a doğru teşvik eder, ancak ağırlıkları asla sıfıra kadar itmez.

III. Aşırı Uyum: L_2 Düzenlemesi

1. L_2 Düzenleme Oranı (lambda): Belirttiğimiz gibi, eğitim süreci, kayıp ve karmaşıklığın bazı kombinasyonlarını en aza indirmeye çalışır, şöyle ki;

$$\text{minimize } (loss + complexity)$$

2. Model geliştiricileri, karmaşıklığın model eğitimi üzerindeki genel etkisini, değerini düzenleme oranı (regularization rate) adı verilen bir skaler ile çarparak ayarlar.
3. Yunan karakteri lambda tipik olarak düzenleme oranını sembolize eder. Yani, model geliştiriciler aşağıdakileri yapmayı hedefler:

$$\text{minimize } (loss + \lambda complexity)$$

III. Aşırı Uyum: L_2 Düzenlemesi

1. Yüksek bir düzenleme oranı;


- a) Düzenlemenin etkisini güçlendirir, böylece aşırı uyum olasılığını azaltır.
- b) Aşağıdaki özelliklere sahip bir model ağırlıkları bir histogramını üretme eğilimindedir:

- 1. normal bir dağılım
- 2. ortalama ağırlığı 0 olan bir dağılım

2. Örneğin, yüksek bir düzenleme oranı için model ağırlıklarının histogramı yanda gösterildiği gibi görünebilir.


3. Yüksek düzenleme oranı için ağırlık histogramında ortalama sıfırdır ve normal dağılım sergilenir.

Model Ağırlıklarının Dağılımı



III. Aşırı Uyum: L_2 Düzenlemesi

1. Düşük bir düzenleme oranı:
 - a) Düzenlemenin etkisini azaltır, böylece aşırı uyum olasılığını artırır.
 - b) Düz bir dağılıma sahip model ağırlıklarının bir histogramını üretme eğilimindedir.
2. Düşük bir düzenleme oranı, aşağıdaki şekilde gösterildiği gibi, daha düz bir histogram üretme eğilimindedir.
3. Düşük düzenleme oranı için ağırlık histogramında ortalama sıfır olabilir veya olmayabilir.



III. Aşırı Uyum: L_2 Düzenlemesi



1. Düzenleme Oranının Seçilmesi: İdeal düzenleştirme oranı, daha önce görülmemiş yeni verilere iyi genelleme yapan bir model üretir. Ne yazık ki, bu ideal değer veriye bağlıdır, bu nedenle bazı ayarlamalar yapmanız gerekir.
 - a) Erken durdurma: Karmaşıklığa dayalı düzenlemeye bir alternatif olarak görülebilir.
 - ✓ Erken durdurma, karmaşıklık hesaplaması içermeyen bir düzenleştirme yöntemidir.
 - ✓ Bunun yerine, erken durdurma basitçe model tamamen yakınsamadan önce eğitimi sonlandırmak anlamına gelir.
 - ✓ Örneğin, doğrulama kümesi için kayıp eğrisi artmaya başladığında (eğim pozitif hale geldiğinde) eğitimi sonlandırabiliriz.
 - ✓ Erken durdurma genellikle eğitim kaybını artırsa da test kaybını azaltabilir.
 - ✓ Erken durdurma hızlı, ancak nadiren optimal bir düzenli hale getirme biçimidir.
 - ✓ Ortaya çıkan modelin, ideal düzenleme oranına göre tamamen eğitilmiş bir model kadar iyi olması pek olası değildir.

III. Aşırı Uyum: L_2 Düzenlemesi

- b) Öğrenme oranı ve düzenleme oranı arasında denge bulma: Öğrenme oranı ve düzenleme oranı ağırlıkları zıt yönlerde çekme eğilimindedir.**
- ✓ Yüksek bir öğrenme oranı genellikle ağırlıkları sıfırdan uzaklaştırır; yüksek bir düzenleme oranı ise ağırlıkları sıfıra doğru çeker.
 - ✓ Düzenleme oranı öğrenme oranına göre yüksekse, zayıf ağırlıklar zayıf tahminler yapan bir model üretme eğilimindedir.
 - ✓ Tersine, öğrenme oranı düzenleme oranına göre yüksekse, güçlü ağırlıklar aşırı uyumlu bir model üretme eğilimindedir.
 - ✓ Amacınız, öğrenme oranı ile düzenleme oranı arasındaki dengeyi bulmaktır. Bu zor olabilir.
 - ✓ En kötüsü de, bu zor dengeyi bulduğunuzda, eninde sonunda öğrenme oranını değiştirmemiz gerekebilir.
 - ✓ Ve öğrenme oranını değiştirdiğimizde, ideal düzenleme oranını tekrar bulmamız gerekecektir.

IV. Kayıp Eğrilerini Yorumlama

1. Modelimizi ilk eğittiğimizde tüm kayıp eğrilerimiz sağ üstteki gibi olsaydı, makine öğrenimi çok daha basit olurdu.
2. Ne yazık ki, kayıp eğrilerini yorumlamak çoğu zaman zordur.
3. Şimdi birkaç örneğe bakalım.
4. Salınlı kayıp eğrisinde gösterilen kayıp eğrisini iyileştirmek için yapabileceğimiz üç şey nedir?
 - a) Öğrenme oranını artırmalı.
 - b) Eğitim setindeki örnek sayısını artırmalıyız.
 - c) Öğrenme oranını azaltmalı.
 - d) Kötü örnekleri tespit etmek için verilerimizi bir veri şemasına göre kontrol etmeli ve ardından kötü örnekleri eğitim setinden çıkarmalıyız.
 - e) Eğitim setini çok az sayıda güvenilir örneğe indirmeli.



IV. Kayıp Eğrilerini Yorumlama

1. Salınlı kayıp eğrisinde gösterilen kayıp eğrisini iyileştirmek için yapabileceğimiz üç şey nedir?
 - a) Öğrenme oranını artırmalı: Genel olarak, bir modelin öğrenme eğrisi bir soruna işaret ettiğinde öğrenme oranını artırmaktan kaçınmalıyız.
 - b) Eğitim setindeki örnek sayısını artırmalıyız: Bu cazip bir fikirdir, ancak aynı kalitede veri eklenecekse sorunu çözme olasılığı son derece düşüktür.
 - c) Öğrenme oranını azaltmalı: Bir eğitim probleminde hata ayıklarken öğrenme oranını düşürmek genellikle iyi bir fikirdir.
 - d) Kötü örnekleri tespit etmek için verilerimizi bir veri şemasına göre kontrol etmeli ve ardından kötü örnekleri eğitim setinden çıkarmalıyız: Bu tüm modeller için iyi bir çözümdür.
 - e) Eğitim setini çok az sayıda güvenilir örneğe indirmeli: Bu teknik kulağa yapay gelse de aslında iyi bir fikirdir. Modelin küçük güvenilir örnekler kümesinde yakınsadığını varsayarsak, daha sonra kademeli olarak daha fazla örnek ekleyebilir, belki de hangi örneklerin kayıp eğrisinin salınmasına neden olduğunu keşfedebiliriz.

IV. Kayıp Eğrilerini Yorumlama


1. Şekilde gösterildiği gibi keskin bir sıçramaya sahip kayıp eğrisinin olası nedenleri nelerdir?
 - a) Giriş verileri bir veya daha fazla NaN içermektedir - örneğin, sıfıra bölme işleminden kaynaklanan bir değer.
 - b) Öğrenme oranı çok düşüktür.
 - c) Girdi verileri bir dizi aykırı değer içeriyor.
 - d) Düzenleştirme oranı çok yüksektir.



IV. Kayıp Eğrilerini Yorumlama

1. Şekilde gösterildiği gibi keskin bir sıçramaya sahip kayıp eğrisinin olası nedenleri nelerdir?
 - a) Giriş verileri bir veya daha fazla NaN içermektedir - örneğin, sıfıra bölme işleminden kaynaklanan bir değer: Bu, tahmin ettiğinizden daha yaygındır bu nedenle kontrol edilmelidir.
 - b) Öğrenme oranı çok düşüktür: Çok düşük bir öğrenme oranı eğitim süresini artırabilir, ancak garip kayıp eğrisinin nedeni bu değildir.
 - c) Girdi verileri bir dizi aykırı değer içeriyor: Bazen, iş partilerin (batch) yanlış karıştırılması nedeniyle, bir iş partisi çok sayıda aykırı değer içerebilir.
 - d) Düzenleştirme oranı çok yüksektir: Kısmen. Çok yüksek bir düzenlileştirme modelin yakınsamasını engelleyebilir; ancak bu sıçramaya neden olmaz.


Kayıpta keskin artış.



IV. Kayıp Eğrilerini Yorumlama

1. Aşağıdaki ifadelerden hangisi eğitim ve test setlerinin kayıp eğrileri arasındaki bu farkın nedenini en iyi şekilde tanımlar?
 - a) Öğrenme oranı çok yüksek.
 - b) Model eğitim setine aşırı uyum sağlıyor.

Doğrulamada keskin artış.




IV. Kayıp Eğrilerini Yorumlama

1. Aşağıdaki ifadelerden hangisi eğitim ve test setlerinin kayıp eğrileri arasındaki bu farkın nedenini en iyi şekilde tanımlar?
2. Öğrenme oranı çok yüksek. Öğrenme oranı çok yüksek olsaydı, eğitim seti için kayıp eğrisi muhtemelen olduğu gibi davranmazdı.
3. Model eğitim setine aşırı uyum sağlıyor. Muhtemelen

Olası çözümler:

1. Muhtemelen özellik sayısını azaltarak modeli daha basit hale getirebiliriz.
2. Düzeltilme oranını artırabiliriz.
3. Eğitim seti ve test setinin istatistiksel olarak eşdeğer olduğundan emin olmalıyız.


Doğrulamada keskin artış.



IV. Kayıp Eğrilerini Yorumlama

1. Aşağıdaki ifadelerden hangisi şekilde gösterilen düzensiz kayıp eğrisi için en olası açıklamadır?
 - a) Eğitim seti çok fazla özellik içermektedir.
 - b) Düzenli hale getirme oranı (regularization rate) çok yüksektir.
 - c) Eğitim seti tekrarlayan örnek dizileri içermektedir.


Belirli bir adım sayısından sonra düzensiz kayıp.



IV. Kayıp Eğrilerini Yorumlama

1. Aşağıdaki ifadelerden hangisi şekilde gösterilen düzensiz kayıp eğrisi için en olası açıklamadır?
 - a) Eğitim seti çok fazla özellik içermektedir.
 - b) Düzenli hale getirme oranı (regularization rate) çok yüksektir.
 - c) Eğitim seti tekrarlayan örnek dizileri içermektedir: Muhtemelen. Örnekleri yeterince karıştırdığımızdan emin olmalıyız.

Belirli bir adım sayısından sonra düzensiz kayıp.



Birkaç Soru

Sabit sayıda örneğe sahip tek bir veri kümesi verildiğinde, aşağıdaki ifadelerden hangisi doğrudur?

- a) Modeli test etmede kullanılan her örnek, modeli eğitmede kullanılanlardan bir örnek daha azdır.**
- b) Test setindeki örnek sayısı, doğrulama setindeki veya eğitim setindeki örnek sayısından fazla olmalıdır.**
- c) Test setindeki örnek sayısı, doğrulama setindeki örnek sayısından fazla olmalıdır.**

Birkaç Soru

Sabit sayıda örneğe sahip tek bir veri kümesi verildiğinde, aşağıdaki ifadelerden hangisi doğrudur?

- a) Modeli test etmede kullanılan her örnek, modeli eğitmede kullanılandan bir örnek daha azdır: Örnekleri eğitim/test/doğrulama kümelerine bölmek sıfır toplamlı bir oyundur. Bu, temel değiş tokuşu ifade eder.
- b) Test setindeki örnek sayısı, doğrulama setindeki veya eğitim setindeki örnek sayısından fazla olmalıdır: Eğitim setindeki örnek sayısı genellikle doğrulama setindeki veya test setindeki örnek sayısından çok daha fazladır.
- c) Test setindeki örnek sayısı, doğrulama setindeki örnek sayısından fazla olmalıdır: Teoride doğrulama kümesi ve test kümesi aynı sayıda veya yakın sayıda örnek içermelidir.

Birkaç Soru

Diyelim ki test setimiz istatistiksel olarak anlamlı bir test gerçekleştirmek için yeterli örnek içeriyor. Dahası, test setiyle test yapmak düşük kayıpla sonuçlanır. Ancak, model gerçek dünyada kötü performans gösterdi. Ne yapmalıyız?

- a) Aynı test kümesi üzerinde yeniden test ederiz. Bazen test sonuçları bir anomali olabilir.
- b) Orijinal veri setinin gerçek hayattaki verilerden ne kadar farklı olduğunu belirleriz.

Birkaç Soru

Diyelim ki test setimiz istatistiksel olarak anlamlı bir test gerçekleştirmek için yeterli örnek içeriyor. Dahası, test setiyle test yapmak düşük kayıpla sonuçlanır. Ancak, model gerçek dünyada kötü performans gösterdi. Ne yapmalıyız?

- a) Aynı test kümesi üzerinde yeniden test ederiz. Bazen test sonuçları bir anomali olabilir.
- b) Orijinal veri setinin gerçek hayattaki verilerden ne kadar farklı olduğunu belirleriz: En iyi veri kümeleri bile gerçek hayattaki verilerin yalnızca bir anlık görüntüsüdür; altta yatan temel gerçek zaman içinde değişme eğilimindedir. Test setiniz eğitim setinizle iyi bir model kalitesi gösterecek kadar iyi eşleşse de, veri setiniz muhtemelen gerçek dünya verileriyle yeterince eşleşmiyordur. YENİ BİR veri kümesine karşı yeniden eğitmeniz ve yeniden test etmeniz gerekebilir.

Birkaç Soru

Test seti kaç örnek içermelidir?

- a) İstatistiksel olarak anlamlı bir test elde etmek için yeterli sayıda örnek.**
- b) Orijinal veri kümesinin en az %15'i.**

Birkaç Soru

Test seti kaç örnek içermelidir?

- a) İstatistiksel olarak anlamlı bir test elde etmek için yeterli sayıda örnek: Bu genelde deneyler ile belirlenir.
- b) Orijinal veri kümesinin en az %15'i.

Birkaç Soru

Aşağıdaki veri kümesi bölümlerini %70'i eğitim seti, %15'i doğrulama seti ve %15'i test seti olarak göz önünde bulundurun.

Eğitim Kümesi	Doğrulama Kümesi	Test Kümesi
---------------	------------------	-------------

Eğitim setindeki örneklerin doğrulama setindeki ve test setindeki örneklerle benzer bir istatistiksel dağılıma sahip olmasını sağlamak için ne yapmalıyız?

- a) Örnekler en eskiden en yeniye doğru sıralanmalı.
- b) Hiçbir şey yapılmaz. Yeterli sayıda örnek verildiğinde, ortalamalar yasası doğal olarak dağılımların istatistiksel olarak benzer olmasını sağlar.
- c) Veri kümesindeki örnekler bölümlere ayırmadan önce kapsamlı bir şekilde karıştırılmalı.

Birkaç Soru

Aşağıdaki veri kümesi bölümlerini %70'i eğitim seti, %15'i doğrulama seti ve %15'i test seti olarak göz önünde bulundurun.

Eğitim setindeki örneklerin doğrulama setindeki ve test setindeki örneklerle benzer bir istatistiksel dağılıma sahip olmasını sağlamak için ne yapmalıyız?

- a) Örnekler en eskiden en yeniye doğru sıralanmalı: Veri setindeki örnekler durağan değilse, sıralama bölümleri daha az benzer hale getirir.
- b) Hiçbir şey yapılmaz. Yeterli sayıda örnek verildiğinde, ortalamalar yasası doğal olarak dağılımların istatistiksel olarak benzer olmasını sağlar: Veri setinin belirli bölümlerindeki örnekler diğer bölümlerdeki örneklerden farklı olabilir.
- c) Veri kümesindeki örnekler bölümlere ayırmadan önce kapsamlı bir şekilde karıştırılmalı: Örneklerin iyi bir şekilde karıştırılması, bölümlerin istatistiksel olarak benzer olma olasılığını çok daha fazla artırır.

Birkaç Soru

Bir yayın hizmeti, önümüzdeki üç yıl için potansiyel yeni televizyon programlarının popülaritesini tahmin etmek için bir model geliştiriyor. Yayın hizmeti, modeli önceki on yılı kapsayan yüz milyonlarca örnek içeren bir veri kümesi üzerinde eğitmeyi planlıyor. Bu model bir sorunla karşılaşacak mı?

- a) Muhtemelen hayır. İzleyicilerin zevkleri öngörülebilir şekilde döngüsel şekillerde değişir. On yıllık veri, modelin gelecekteki eğilimler hakkında iyi tahminlerde bulunmasını sağlayacaktır.
- b) Kesinlikle hayır. Veri kümesi iyi tahminlerde bulunmak için yeterince büyük.
- c) Muhtemelen. İzleyicilerin zevkleri, geçmiş davranışların tahmin edemeyeceği şekillerde değişir.

Birkaç Soru

Bir yayın hizmeti, önümüzdeki üç yıl için potansiyel yeni televizyon programlarının popülaritesini tahmin etmek için bir model geliştiriyor. Yayın hizmeti, modeli önceki on yılı kapsayan yüz milyonlarca örnek içeren bir veri kümesi üzerinde eğitmeyi planlıyor. Bu model bir sorunla karşılaşacak mı?

- a) Muhtemelen hayır. İzleyicilerin zevkleri öngörülebilir şekilde döngüsel şekillerde değişir. On yıllık veri, modelin gelecekteki eğilimler hakkında iyi tahminlerde bulunmasını sağlayacaktır: Eğlencenin belirli yönleri bir şekilde döngüsel olsa da, geçmiş eğlence tarihinden eğitilen bir model, önümüzdeki birkaç yıl hakkında tahmin yapmakta neredeyse kesinlikle zorlanacaktır.
- b) Kesinlikle hayır. Veri kümesi iyi tahminlerde bulunmak için yeterince büyük: Ne yazık ki izleyicinin beğenileri durağan değil.
- c) Muhtemelen. İzleyicilerin zevkleri, geçmiş davranışların tahmin edemeyeceği şekillerde değişir: İzleyici zevkleri durağan değildir. Sürekli değişirler.

Birkaç Soru

Bir model, hava durumu mevsime göre önemli ölçüde değişen bir şehirde bir yıl boyunca toplanan hava durumu verilerine (sıcaklık, çığ noktası ve yağış) dayanarak insanların bir kilometre yürümesi için gereken süreyi tahmin etmeyi amaçlamaktadır. Hava durumu okumaları mevsime göre önemli ölçüde değişse bile, bu veri setinden bir model oluşturabilir ve test edebilir miyiz?

- a) Hayır**
- b) Evet**

Birkaç Soru

Bir model, hava durumu mevsime göre önemli ölçüde değişen bir şehirde bir yıl boyunca toplanan hava durumu verilerine (sıcaklık, çığ noktası ve yağış) dayanarak insanların bir kilometre yürümesi için gereken süreyi tahmin etmeyi amaçlamaktadır. Hava durumu okumaları mevsime göre önemli ölçüde değişse bile, bu veri setinden bir model oluşturabilir ve test edebilir miyiz?

a) Hayır

b) Evet: Bu veri setinden bir model oluşturmak ve test etmek mümkündür. Tek yapmanız gereken verilerin eşit şekilde bölümlere ayrıldığından emin olmaktır, böylece dört mevsimden gelen veriler farklı bölümlere eşit şekilde dağıtılır.

Birkaç Soru

Bir fizik denklemi geliştiriyorsunuz. Aşağıdaki formüllerden hangisi Occam'ın Usturasına daha yakındır?

- a) On iki değişkenli bir formül.**
- b) Üç değişkenli bir formül.**

Birkaç Soru

Bir fizik denklemi geliştiriyorsunuz. Aşağıdaki formüllerden hangisi Occam'ın Usturasına daha yakındır?

- a) On iki değişkenli bir formül.**
- b) Üç değişkenli bir formül.**

Birkaç Soru

Yepyeni bir makine öğrenimi projesindesiniz ve ilk özelliklerinizi seçmek üzeresiniz. Kaç özellik seçmelisiniz?

- a) Güçlü tahmin gücüne sahip gibi görünen 4-6 özellik seçin.**
- b) Güçlü tahmin gücüne sahip gibi görünen 1-3 özellik seçin.**
- c) Mümkün olduğunca çok özellik seçin, böylece hangi özelliklerin en güçlü tahmin gücüne sahip olduğunu gözlemlemeye başlayabilirsiniz.**

Birkaç Soru

Yepyeni bir makine öğrenimi projesindesiniz ve ilk özelliklerinizi seçmek üzeresiniz. Kaç özellik seçmelisiniz?

- a) Güçlü tahmin gücüne sahip gibi görünen 4-6 özellik seçin.
- b) Güçlü tahmin gücüne sahip gibi görünen 1-3 özellik seçin: Veri toplama hattınız için yalnızca bir veya iki özellik ile başlamak en iyisidir. Bu, ML modelinin amaçlandığı gibi çalıştığını doğrulamamıza yardımcı olacaktır. Ayrıca, birkaç özellikten bir temel oluşturduğumuzda, ilerleme kaydettiğinizi hissederiz.
- c) Mümkün olduğunca çok özellik seçin, böylece hangi özelliklerin en güçlü tahmin gücüne sahip olduğunu gözlemlemeye başlayabilirsiniz.

Birkaç Soru

1. Bir modeli eğitirken L_2 düzenlemesini kullanırsanız, modelin genel karmaşıklığına genellikle ne olur?
 - a) Modelin genel karmaşıklığı muhtemelen artacaktır.
 - b) Modelin genel karmaşıklığı muhtemelen sabit kalacaktır.
 - c) Sistemin genel karmaşıklığı muhtemelen düşecektir.

Birkaç Soru

1. Bir modeli eğitirken L_2 düzenlemesini kullanırsanız, modelin genel karmaşıklığına genellikle ne olur?
 - a) Modelin genel karmaşıklığı muhtemelen artacaktır.
 - b) Modelin genel karmaşıklığı muhtemelen sabit kalacaktır.
 - c) Sistemin genel karmaşıklığı muhtemelen düşecektir: L_2 düzenlemesi ağırlıkların 0'a doğru ilerlemesini teşvik ettiğinden, genel karmaşıklık muhtemelen düşecektir.

Birkaç Soru

1. Bir modeli eğitirken L_2 düzenlemesini kullanırsanız, modelden bazı özellikler kaldırılacaktır.
 - a) Doğru
 - b) Yanlış

Birkaç Soru

1. Bir modeli eğitirken L_2 düzenlemesini kullanırsanız, modelden bazı özellikler kaldırılacaktır.
 - a) Doğru
 - b) Yanlış: L_2 düzenlemesi ağırlıkları hiçbir zaman sıfıra kadar itmeyeceği için bazı özellikler kaldırılmaz

Birkaç Soru: Açık Uçlu

Belirli bir rota için yolcuların tren bileti satın alabilecekleri ideal tarihi tahmin eden bir model oluşturuyorsunuz.

Örneğin, model kullanıcıların 23 Temmuz'da kalkan bir tren için 8 Temmuz'da bilet satın almalarını önerebilir. Tren şirketi, fiyat güncellemelerini çeşitli faktörlere, ancak esas olarak mevcut koltuk sayısına dayanarak saatlik olarak günceller. Yani:

- **Çok sayıda koltuk varsa, bilet fiyatları genellikle düşüktür.**
- **Çok az koltuk varsa, bilet fiyatları genellikle yüksektir.**

Modeliniz doğrulama kümesinde ve test kümesinde düşük kayıp sergiliyor ancak bazen gerçek dünya verilerinde korkunç tahminlerde bulunuyor. Neden?

Birkaç Soru: Açık Uçlu

Gerçek dünya modeli öneri geri bildirim döngüsüyle mücadele eder.

Örneğin, modelin kullanıcıların 8 Temmuz'da bilet satın almasını önerdiğini varsayalım.

Modelin önerisini kullanan bazı yolcular biletlerini 8 Temmuz sabahı 8:30'da satın alıyor.

Saat 9:00'da tren şirketi fiyatları artırıyor çünkü artık daha az koltuk mevcut.

Modelin önerisini kullanan yolcular fiyatları değiştirmiş oldu.

Bu nedenle akşam saatlerinde bilet fiyatları önerinin yapıldığı sabah saatlerine göre çok daha yüksek olabilir.

Kaynaklar

- 1) Yapay Öğrenme, Ethem ALPAYDIN
- 2) Understanding Machine Learning: From Theory to Algorithms, Shai Shalev-Shwartz, Shai Ben-David