

Makine Öğrenmesi

Ders 9



Bu Dersin İçeriği


- I. Sinir Ağları Nedir?
- II. Düğümler ve Gizli Katmanlar
- III. Aktivasyon (Etkinleştirme) İşlevleri

I. Sinir Ağları

1. Bu konu ile neler öğreneceğiz?
 - a) Sinir ağları oluşturma motivasyonunu ve ele aldıkları kullanım durumlarını açıklama.
 - b) Derin bir sinir ağı mimarisinin temel bileşenlerinin işlevini tanımlayın ve açıklama:
 - 1) Düğümler
 - 2) Gizli katmanlar
 - 3) Etkinleştirme işlevleri
 - c) Çıkarım sürecini adım adım izleyerek sinir ağı tahminlerinin nasıl yapıldığına dair sezgi geliştirme
 - d) Geri yayılım algoritmasını kullanarak sinir ağlarının nasıl eğitildiğine dair üst düzey bir sezgi oluşturma
 - e) Sinir ağlarının iki tür çoklu sınıflı sınıflandırma gerçekleştirmek için nasıl kullanılabileceğini açıklama: bire karşı hepsi (one-vs.-all) ve bire karşı bir (one-vs.-one.)

I. Sinir Ağları

1. Kategorik veri konusunda Özellik çaprazlama konusunda aşağıdaki sınıflandırma probleminin doğrusal olmadığını anlayabiliriz;
2. Sadece bir doğrusal fonksiyon tüm mavi noktaları turuncu noktalardan temiz bir şekilde ayıramaz.
3. “Doğrusal olmayan” teriminin anlamı, $b + w_1x_1 + w_2x_2$ biçimindeki bir modelle bir etiketi doğru bir şekilde tahmin edemeyeceğiniz anlamına gelir.
4. Başka bir deyişle, “karar yüzeyi” bir doğru değildir.




I. Sinir Ağları

1. Ancak, ve x_1 ve x_2 özelliklerimiz üzerinde bir özellik çaprazlaması yaparsak, o zaman iki özellik arasındaki doğrusal olmayan ilişkiyi doğrusal bir model kullanarak gösterebiliriz:


$$b + w_1x_1 + w_2x_2 + w_3x_3$$

1. Burada x_3 , x_1 ve x_2 arasındaki özellik çaprazlamasıdır:
2. x_1x_2 özellik çaprazı eklenerek doğrusal model, mavi noktaları turuncu noktalardan ayıran hiperbolik bir şekil öğrenebilir.



I. Sinir Ağları

1. Tüm bunların yanında daha zor bir doğrusal olmayan sınıflandırma problemi olan aşağıdaki veri setini ele alalım:
2. Playground'taki, (<https://playground.tensorflow.org/>) özellik çaprazlama alıştırmalarından, bu verilere doğrusal bir model uydurmak için doğru özellik çaprazlarını belirlemenin biraz daha fazla çaba ve deneme gerektirdiğini hatırlayabiliriz. (Ders-7)




I. Sinir Ağları

1. Peki ya tüm bu deneyleri kendiniz yapmak zorunda olmasaydınız?
2. Sinir ağları yapıları, verilerdeki bu şekilde doğrusal olmayan örüntüleri bulmak için tasarlanmış bir model mimarisi ailesidir.
3. Bir sinir ağının eğitimi sırasında model, kaybı en aza indirmek için giriş verileri üzerinde gerçekleştirilecek en uygun özellik çaprazlarını bulmak yerine bünyesindeki katmanlar aracılığıyla karmaşık ilişkileri öğrenir.

I. Sinir Ağları

1. Biyolojik sinir hücresinin yapısı yandaki şekilde gösterilmektedir. Biyolojik bir nöron, dendrit, hücre gövdesi, akson ve sinapstan oluşur.
2. Dendrit, diğer nöronlardan gelen sinyalleri hücre gövdesine iletir.
3. Hücre gövdesi, nöronun çekirdeğini içerir ve dendritlerden gelen tüm sinyalleri toplar.
4. Aksonlar, hücre gövdesinden gelen tüm sinyalleri sinapslara aktarmaktan sorumludur.
5. Sinapslar, aksondan gelen tüm bilgileri ön işleme tabi tuttukten sonra başka bir nöron hücresinin dendritine aktarır.



I. Sinir Ağları

1. Sinaps tarafından yapılan bu ön işleme çok önemlidir.
2. Çünkü bu ön işleme, belirli bir eşik değerine göre tüm sinyallerin değiştirilmesinden oluşur.
3. Böylece, toplam sinyal belirli bir aralığa indirgenir ve olduğu gibi başka bir nörona iletilmez.
4. Bu açıdan bakıldığında, aksondan gelen ve dendrite iletilen her toplam sinyal arasında bir korelasyon oluşur.
5. Bu noktadan hareketle, öğrenme sürecinin sinapslarda gerçekleştiği hipotezi ortaya çıkmıştır.
6. Bu hipoteze dayanarak, YSA modelinin öğrenme süreci, dendrit ve sinaps arasındaki ağırlık katsayılarının güncellenmesi olarak algılanmaktadır.


I. Sinir Ağları

1. Böylece, bu hipotez teoriye dönüştürülebilir ve biyolojik nöronun bu çalışma şekline ilham alarak yapay nöron tasarlanabilir (Fausett, 1994).
2. Yapay nöron hücresi (ANC), gerçek biyolojik nöron hücresi yapısı ve çalışma şekline dayalı olarak geliştirilmiştir. ANC ve biyolojik nöron hücresinin karşılaştırması aşağıdaki tabloda verilmiştir.

Sinir Sisteminin Bileşeni	Yapay Sinir Ağının Bileşeni
Sinir Hücresi	Yapay Sinir Hücresi
Sinaps	Ağırlıklar
Dendrite	Toplama İşlevi
Hücre Gövdesi	İletim (Transfer) İşlevi
Aksonlar (Axons)	Hücre çıkışı-çıktısı


I. Sinir Ağları

1. Bu tablo kullanılarak oluşturulan ANC'nin temel yapısı aşağıdaki şekilde verilmiştir.



2. ANC'nin dendriti x_n olarak gösterilmiştir ve her dendritin ağırlıkları (önem derecesi) w_n olarak gösterilmiştir.
3. Böylece x_n giriş sinyallerini temsil eder ve w_n bu sinyallerin ağırlıklarını temsil eder.
4. Tüm giriş sinyallerinin ağırlıklı toplamı, hücre gövdesindeki toplama fonksiyonu ile elde edilir.
5. Bu toplam sinyal y_k olarak gösterilir ve sinapstaki eşik fonksiyonuna yönlendirilir.

I. Sinir Ağları



$$y_k = \sum_{i=1}^h x_i * w_i$$

Toplama İşlevi


1. Eşik fonksiyonunun sonucu y olarak tanımlanır ve başka bir ANC'ye besleme için yönlendirilir.
2. ANC'nin amacı, giriş değerlerine yanıt olarak çıkış sinyali oluşturmak ve bu çıkış değerlerini başka bir ANC'ye iletmektir. x_n ve y arasındaki korelasyonu temsil eden ağırlıklar, her yeni giriş ve çıkış sinyaline göre yeniden düzenlenir.
3. Bu düzenleme süreci öğrenme olarak adlandırılır.
4. Öğrenme süreci, kaybı en aza indiren ağırlıkların değişimi sabitleşene kadar devam eder.
5. ANN (Yapay Sinir Ağları) ise , katmanlı bir yapıda birbirine bağlı ANC'ler tarafından oluşturulur.

I. Sinir Ağları

- 1. Girdiler:** Bir yapay sinir hücresine dış dünyadan bilgilerdir. Bunlar ağın öğrenmesi istenen örnekler tarafından belirlenir. Yapay sinir hücresine dış dünyadan olduğu gibi başka hücrelerden veya kendi kendisinden de bilgiler gelebilir.
- 2. Ağırlıklar:** Ağırlıklar bir yapay hücreye gelen bilginin önemini ve hücre üzerindeki etkisini gösterir. Ağırlıkların büyük yada küçük olması önemli veya önemsiz olduğu anlamına gelmez. Bir ağırlığın değerinin sıfır olması o ağ için en önemli olay olabilir. Eksi değerler önemsiz demek değildir. O nedenle artı veya eksi olması etkisinin pozitif veya negatif olduğunu gösterir. Sıfır olması ise herhangi bir etkinin olmadığını gösterir. Ağırlıklar değişken veya sabit değerler olabilirler.
- 3. Toplama fonksiyonu:** Bu fonksiyon, bir hücreye gelen net girdiyi hesaplar. Bunun için değişik fonksiyonlar kullanılmaktadır. En yaygın olanı ağırlıklı toplamı bulmaktır. Burada her gelen girdi değeri kendi ağırlığı ile çarpılarak toplanır. Böylece ağa gelen net girdi bulunmuş olur.

I. Sinir Ağları

Tek bir Perceptron (tek hücreli algılayıcı) matematiksel olarak ifade edelim.



$$f = \begin{cases} 0 & \text{if } \sum_j w_j x_j \leq -b \\ 1 & \text{if } \sum_j w_j x_j > -b \end{cases}$$

where, $w_j = \text{weights}$
 $b = \text{bias (threshold)}$


$$f = \begin{cases} 0 & \text{if } \mathbf{w} \cdot \mathbf{x} + b \leq 0 \\ 1 & \text{if } \mathbf{w} \cdot \mathbf{x} + b > 0 \end{cases}$$

Kaynak: Shree Nayar, Perceptron | Neural Networks

I. Sinir Ağları

Let: $z = w \cdot x + b$


$$\text{Activation: } a = f(z) = \begin{cases} 0 & \text{if } z \leq 0 \\ 1 & \text{if } z > 0 \end{cases}$$



Bir Perceptron (tek hücreli algılayıcı) için Aktivasyon Fonksiyonu bir Basamak Fonksiyonudur.


I. Sinir Ağları

Tek bir Perceptron (tek hücreli algılayıcı) ile ne yapılabilir?




I. Sinir Ağları

Tek bir Perceptron (tek hücreli algılayıcı) ile ne yapılabilir?




I. Sinir Ağları

Tek bir Perceptron (tek hücreli algılayıcı) ile ne yapılabilir?



I. Sinir Ağları


Tek bir Perceptron (tek hücreli algılayıcı) ile ne yapılabilir?



Peki sinemaya gidilecek mi?

I. Sinir Ağları


Tek bir Perceptron (tek hücreli algılayıcı) ile ne yapılabilir?



Peki sinemaya gidilecek mi? Hayır

I. Sinir Ağları


Tek bir Perceptron (tek hücreli algılayıcı) ile ne yapılabilir?



Peki sinemaya gidilecek mi?

I. Sinir Ağları


Tek bir Perceptron (tek hücreli algılayıcı) ile ne yapılabilir?



Peki sinemaya gidilecek mi? Evet

I. Sinir Ağları


Bir sinir ağına daha yakından bakalım.



- Diyelim ki burası düz bir çizgi olsun.

I. Sinir Ağları


Bir sinir ağına daha yakından bakalım.



- Burada olan şudur:Eğer x_1 , x_2 değerleri düz çizginin üzerinde veya sağında yer alıyorsa,bu durumda z , 0'dan küçük veya 0'a eşit olacaktır.
- Ve dolayısıyla, çıktı veya aktivasyon 0'a eşit olacaktır.

I. Sinir Ağları


Bir sinir ağına daha yakından bakalım.



- Öte yandan, eğer çizginin sol tarafında yer alıyorsanız, z 0'dan büyük olacaktır.
- Ve çıktı veya aktivasyon 1'e eşit olacaktır.
- İşte algılayıcı (perceptron) bunu yapıyor.
- Doğrusal bir sınıflandırıcı gibi davranıyor.
- Doğrusal sınıflandırıcılar hakkında konuştuk.

I. Sinir Ağları


Bir sinir ağına daha yakından bakalım.



- Girişlerin ikili (binary) olduğunu varsayalım.
- Yani girişler ikili ise, 0 veya 1 ise, algılayıcıya yalnızca dört olası giriş vardır.
- Burada (0, 0), (1, 0), (0, 1) ve (1, 1) var.
- Bunlar dört girişi oluşturur.

I. Sinir Ağları

Bir sinir ağına daha yakından bakalım.




- Bu girdilere dayanarak, çıktılarının ne olacağını bakalım

I. Sinir Ağları

Bir sinir ağına daha yakından bakalım.

x_1	x_2	a
0	0	1
0	1	1
1	0	1
1	1	0



I. Sinir Ağları


Bir sinir ağına daha yakından bakalım.

x_1	x_2	a
0	0	1
0	1	1
1	0	1
1	1	0



I. Sinir Ağları

Bir sinir ağına daha yakından bakalım.



I. Sinir Ağları

Bir sinir ağına daha yakından bakalım.




Herhangi bir Dijital Mantık Devresi, Perceptro kullanılarak uygulanabilir.

Perceptronlar hesaplama evrenselliği sağlar.


I. Sinir Ağları

Bir sinir ağına daha yakından bakalım.

Dijital Mantık Devresi



Eşdeğer Algılayıcı Ağı



I. Sinir Ağları

1. Toplama fonksiyonu: Literatürde kullanılan birçok toplama fonksiyonu vardır.

İşlev	İşlem	Denklem	Özellik ve Kullanım
Çarpım (Product)	Girdiler çarpılarak birleştirilir.	$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n x_i$	Eğer girdilerden biri 0 ise çıktı da 0 olur. Bulanık mantık sistemlerinde AND (ve) işleminin genelleştirilmiş hali olarak kullanılır.
Maksimum (Maximum)	Girdiler arasından en büyüğü seçilir.	$f(x_1, x_2, \dots, x_n) = \max(x_1, x_2, \dots, x_n)$	Gürültüye karşı dayanıklı; büyük bir değer baskın çıkar. Özellikle çıkarım sistemlerinde en baskın kuralı seçmek için.
Minimum (Minimum)	Girdiler arasından en küçüğü seçilir.	$f(x_1, x_2, \dots, x_n) = \min(x_1, x_2, \dots, x_n)$	Bulanık mantıkta AND (ve) işlemi için en sık kullanılan yöntemdir.
Çoğunluk (Majority / Median)	Girdilerden en çok tekrar eden ya da ortanca (median) değer seçilir.		Gürültülü ortamlarda çoğunluğun kararı daha güvenilir olur. Örn. tıbbi teşhiste farklı sensörlerin kararlarının çoğunluğu alınabilir.

I. Sinir Ağları

1. Toplama fonksiyonu: Literatürde kullanılan birçok toplama fonksiyonu vardır.

İşlev	İşlem	Denklem	Özellik ve Kullanım
Kümülatif Toplam (Cumulative Sum)	Girdiler ardışık toplanır.	$S_k = \sum_{i=1}^k x_i, \quad k = 1, 2, \dots, n$	Zaman serisi verilerinde eğilimi görmek için uygundur (ör. kan şekeri düzeyleri, hasta izleme verileri).
Aritmetik Ortalama (Arithmetic Mean)	Girdiler toplanarak birleştirilir.	$f(x_1, \dots, x_n) = \frac{1}{n} \sum_{i=1}^n x_i$	
Ağırlıklı Ortalama (Weighted Mean)		$f(x_1, \dots, x_n) = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$	Bazı girişler daha önemliyse kullanılır. (Örn. tıbbi kararda bir biyomarker diğerinden daha kritik olabilir).
Softmax Fonksiyonu	Girdileri olasılık dağılımına dönüştürür:	$f(x_i) = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}}$	Sinir ağlarında çok sınıflı sınıflandırma problemlerinde yaygın.

I. Sinir Ağları

1. Farklı yapay zeka uygulamaları kullanan çeşitli ANN türleri bulunmaktadır. En yaygın olarak kullanılan ANN türleri aşağıda sıralanmıştır:
 - ▶ **Feed-Forward Networks (İleri Beslemeli Ağlar):** Girdiden çıktıya doğru tek yönlü bilgi akışı vardır, geri besleme yoktur. En temel YSA mimarisidir.
 - ▶ **Radial Basis Function Networks (Radyal Taban Fonksiyonlu Ağlar):** Gizli katmanda radyal tabanlı aktivasyon fonksiyonları kullanılır. Özellikle sınıflandırma ve fonksiyon yaklaşımı için uygundur.
 - ▶ **Recurrent Networks (Tekrarlayan / Yinelemeli Ağlar):** Çıkışlar tekrar girişlere bağlanabilir. Zaman serisi, dil işleme gibi sıradüzenli veriler için kullanılır.
 - ▶ **Echo State Networks (Yankı Durum Ağları):** Recurrent ağların bir çeşidi; rastgele ağırlıklarla donatılmış, yalnızca çıkış ağırlıkları öğrenilir. Dinamik zaman serisi modellemede kullanılır.

I. Sinir Ağları

1. Farklı yapay zeka uygulamaları kullanan çeşitli ANN türleri bulunmaktadır. En yaygın olarak kullanılan ANN türleri aşağıda sıralanmıştır:
 - ▶ **Hopfield Networks (Hopfield Ağları):** Tam bağlantılı ve simetrik bağlantılara sahip, enerji tabanlı geri beslemeli ağlardır. Özellikle bellek ve optimizasyon problemleri için geliştirilmiştir.
 - ▶ **Self-Organizing Maps (Kohonen Kendini Düzenleyen Haritalar):** Denetimsiz öğrenme tabanlıdır. Yüksek boyutlu veriyi 2B harita üzerinde görselleştirmek için kullanılır.

I. Sinir Ağları

1. Farklı yapay zeka uygulamaları kullanan çeşitli ANN türleri bulunmaktadır. En yaygın olarak kullanılan ANN türleri aşağıda sıralanmıştır:

- ▶ **Convolutional Neural Networks (Evrişimsel Sinir Ağları, CNN):** Görüntü işleme, nesne tanıma, bilgisayarla görü gibi alanlarda yaygın olarak kullanılır.
- ▶ **Long Short-Term Memory Networks (Uzun Kısa Süreli Bellek Ağları, LSTM):** RNN'in geliştirilmiş bir türüdür. Zaman serisi, doğal dil işleme gibi uzun bağımlılıklı dizilerde çok başarılıdır.
- ▶ **Gated Recurrent Units (Kapılı Tekrarlayan Birimler, GRU):** LSTM'nin daha basit ama benzer amaçlı bir versiyonudur. Daha hızlıdır olduğunu bulgulayan çalışmalar vardır.

I. Sinir Ağları

1. Farklı yapay zeka uygulamaları kullanan çeşitli ANN türleri bulunmaktadır. En yaygın olarak kullanılan ANN türleri aşağıda sıralanmıştır:

- ▶ **Generative Adversarial Networks (Üretici Çekişmeli Ağlar, GAN):** Üretici (generator) ve ayırt edici (discriminator) olmak üzere iki ağın karşılıklı rekabeti üzerine kuruludur. Görüntü üretimi ve sahte veri üretiminde kullanılmaktadır.
- ▶ **Autoencoders (Otokodlayıcılar):** Veriyi sıkıştırma (encoding) ve tekrar üretme (decoding) üzerinden öğrenir. Özellikle boyut indirgeme ve anomali tespitinde kullanılır.
- ▶ **Spiking Neural Networks (Dürtüsel / Spike Tabanlı Sinir Ağları):** Biyolojik sinir sistemine daha yakın olan, nöronların zamanlama bilgisiyle çalışan ağlardır.

I. Sinir Ağları

- 1. Makine öğrenimi kapsamında bir sinir ağının eğitimi sırasında model, kaybı en aza indirmek için giriş verileri üzerinde gerçekleştirilecek en uygun özellik çaprazlarını ve bunlara ait ağırlık ve ön yargıyı bulmak yerine bünyesindeki katmanlar aracılığıyla girdi verileriyle çıktı bilgileri arasındaki karmaşık ilişkileri öğrenir.**
- 2. Bu nedenle bir sinir ağı modeli, özellikler arası ilişkileri otomatik öğrenir.**
- 3. Bu bazen çaprazlama gibi etki yaratabilir ama doğrudan bir çaprazlama işlemi değildir.**
- 4. Sinir ağları, özellikle doğrusal olmayan ilişkileri modelleyebilme yetenekleri sayesinde klasik regresyondan yöntemlerinden ayrılır.**
- 5. Bu sayede kendi deneme yanılma sürecimize gerek kalmadan kaybı en aza indirgececek özellik çaprazlanmaları tespit edilmiş olur.**

I. Sinir Ağları


1. Sinir ağı modeli, özellikler arası ilişkileri otomatik öğrenir.
2. Bu bazen çaprazlama gibi etki yaratabilir ama doğrudan bir çaprazlama işlemi değildir.
3. Sinir ağları, özellikle doğrusal olmayan ilişkileri modelleyebilme yetenekleri sayesinde klasik regresyondan ayrılır.
4. Bu sayede kendi deneme yanılma sürecimize gerek kalmadan kaybı en aza indirgeyecek özellik çaprazlanmaları tespit edilmiş olur.

II. D    mler ve Gizli Katmanlar

1. Doğrusal olmayan   zellikleri   ğrenen bir sinir ağı oluřturmak i in ařağıdaki tanıdaık model yapısıyla bařlayalım;
2. Yapısı $b + w_1x_1 + w_2x_2 + w_3x_3$ olan doğrusal bir model olsun.
3. Bu denklemi ařağıda g  sterildiğı gibi g  rselleřtirebiliriz, burada, x_1 , x_2 ve x_3     giriř d  ğ  m  zdir (mavi renkte) ve y'   ıkıř d  ğ  m  zdir (yeřil renkte).

GİRİř D  ğ  MLERİ

  IKIř D  ğ  M  




II. D    mler ve Gizli Katmanlar

1. A  ağıdaki modelde ağırlık ve   nyargı deėerleri rastgele ba latılmıştır.
2. $x_1 = 1.0$, $x_2 = 2.0$ ve $x_3 = 3.0$ giri  deėerleri i in $b = 0.06$ olarak hesapladıėızda  ıkı  d    m  n  n deėerini $y' = -0.19$ olarak buluruz.

GİRİ  D    MLERİ

 IKI  D    M  




II. D ğ mler ve Gizli Katmanlar

1. Girdi katmanındaki ikinci d ğ m deęerini $x_2 = 2.5$ olarak alalım.
2. Tekrar hesaplama yaptığımızda  ıktı d ğ m n n deęerinin deęiřtięine dikkat edelim.

GİRİř D ğ MLERİ

 IKIř D ğ M 

Hesaplama Adımları



$$\begin{aligned} &= \text{Linear}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + b) \\ &= \text{Linear}(-0.30 * 1.00 + 0.29 * 2.50 + -0.35 * 3.00 + 0.74) \\ &= \text{Linear}(-0.30 + 0.72 + -1.05 + 0.74) \\ &= \text{Linear}(0.11) \\ &= 0.11 \end{aligned}$$

- G sterilen deęerler y zde birlik basamaęa yuvarlanır.
- Linear() fonksiyonu basit e kendisine iletilen deęeri d nd rmektedir.

II. Döğümler ve Gizli Katmanlar

1. Ağırlık (w_1 , w_2 ve w_3) ve bias (b) parametre deęerlerini inceleyelim.
2. Üçüncü giriş döşümü ağırlıę (w_3) deęerini azaltalım.
3. Ardından, bias deęerini artıralım.



$$\begin{aligned} &= \text{Linear}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + b) \\ &= \text{Linear}(-0.30 * 1.00 + 0.29 * 2.50 + -0.45 * 3.00 + 0.74) \\ &= \text{Linear}(-0.30 + 0.72 + -1.35 + 0.74) \\ &= \text{Linear}(-0.19) \\ &= -0.19 \end{aligned}$$



$$\begin{aligned} &= \text{Linear}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + b) \\ &= \text{Linear}(-0.30 * 1.00 + 0.29 * 2.50 + -0.70 * 3.00 + 0.74) \\ &= \text{Linear}(-0.30 + 0.72 + -2.10 + 0.74) \\ &= \text{Linear}(-0.94) \\ &= -0.94 \end{aligned}$$

II. D    mler ve Gizli Katmanlar

1. A  r  lık (w_1 , w_2 ve w_3) ve bias (b) parametre de  erlerini inceleyelim.
2.     nc   giri   d    m   a  r  l   (w_3) de  erini azaltalım.
3. Ardından, bias de  erini artıralım.



$$\begin{aligned} &= \text{Linear}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + b) \\ &= \text{Linear}(-0.30 * 1.00 + 0.29 * 2.50 + -0.45 * 3.00 + 1.00) \\ &= \text{Linear}(-0.30 + 0.72 + -1.35 + 1.00) \\ &= \text{Linear}(0.07) \\ &= 0.07 \end{aligned}$$



$$\begin{aligned} &= \text{Linear}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + b) \\ &= \text{Linear}(-0.30 * 1.00 + 0.29 * 2.50 + -0.70 * 3.00 + 1.00) \\ &= \text{Linear}(-0.30 + 0.72 + -2.10 + 1.00) \\ &= \text{Linear}(-0.68) \\ &= -0.68 \end{aligned}$$

II. D    mler ve Gizli Katmanlar

1. A a katmanlar ekleme: A ın a ırlık ve  nyargı de erlerini ayarladığınızda, bunun girdi ve  ıktı arasındaki genel matematiksel ilişkiyi de iştirmediğine dikkat etmeliyiz.
2.      modelimiz hala do rusal bir modeldir.
3. Peki ya a a, girdi katmanı ile  ıktı katmanı arasına bir katman daha eklersek ne olur?
4. Sinir a ı terminolojisinde, girdi katmanı ile  ıktı katmanı arasındaki ek katmanlara gizli katmanlar, bu katmanlardaki d    mlere de n ronlar denir.
5. Gizli katmandaki her bir n ronun de eri, do rusal bir modelin  ıktısı ile aynı şekilde hesaplanır.
6. Her bir girdisinin ( nceki a  katmanındaki n ronlar) ve benzersiz bir a ırlık parametresinin  arpımının toplamı artı  nyargı olarak hesaplanır.

II. Düğümler ve Gizli Katmanlar

1. Benzer şekilde, bir sonraki katmandaki nöronlar (burada çıktı katmanı) gizli katmanın nöron değerleri girdi olarak kullanılarak hesaplanır.
2. Bu yeni gizli katman, modelimizin girdi verilerini başka bir parametre seti kullanarak yeniden birleştirmesini sağlar.
3. Peki bu gizli katmanı ekledikten sonra, bu katman modelimizin doğrusal olmayan ilişkileri öğrenmesine yardımcı olabilir mi?


II. D    mler ve Gizli Katmanlar

1. Modele d  rt n  ron i  eren gizli bir katman ekleyelim. $x_1 = 1.0$, $x_2 = 2.0$ ve $x_3 = 3.0$ giri   de  erleri i  in d  rt gizli katman d    m  n   ve   ıkı   d    m  n   de  erini hesaplayalım.

G  R   D    MLER  

G  ZL   KATMAN

  IKI   D    M  




II. Döğümler ve Gizli Katmanlar

1. Modele dört nöron içeren gizli bir katman ekleyelim. $x_1 = 1.0$, $x_2 = 2.0$ ve $x_3 = 3.0$ giriş değeri için dört gizli katman döğümünün ve çıkış döğümünün değeri hesaplayalım.

GİRİŞ DÜĞÜMLERİ

GİZLİ KATMAN

ÇIKIŞ DÜĞÜMÜ




II. D    mler ve Gizli Katmanlar

1. Modele d  rt n  ron i  eren gizli bir katman ekleyelim. $x_1 = 1.0$, $x_2 = 2.0$ ve $x_3 = 3.0$ giri   de  erleri i  in d  rt gizli katman d    m  n   ve   ıkı   d    m  n   de  erini hesaplayalım.

GİRİ   D    MLERİ

GİZLİ KATMAN

  IKI   D    M  




II. Döğümler ve Gizli Katmanlar

1. Modele dört nöron içeren gizli bir katman ekleyelim. $x_1 = 1.0$, $x_2 = 2.0$ ve $x_3 = 3.0$ giriş değeri için dört gizli katman döğümünün ve çıkış döğümünün değeri hesaplayalım.

GİRİŞ DÜĞÜMLERİ

GİZLİ KATMAN

ÇIKIŞ DÜĞÜMÜ




II. Döğümler ve Gizli Katmanlar

1. Modele dört nöron içeren gizli bir katman ekleyelim. $x_1 = 1.0$, $x_2 = 2.0$ ve $x_3 = 3.0$ giriş değeri için dört gizli katman döğümünün ve çıkış döğümünün değeri hesaplayalım.

GİRİŞ DÜĞÜMLERİ

GİZLİ KATMAN

ÇIKIŞ DÜĞÜMÜ




II. Döğümler ve Gizli Katmanlar

1. Modele dört nöron içeren gizli bir katman ekleyelim. $x_1 = 1.0$, $x_2 = 2.0$ ve $x_3 = 3.0$ giriş değeri için dört gizli katman döğümünün ve çıkış döğümünün değeri hesaplayalım.

GİRİŞ DÖĞÜMLERİ

GİZLİ KATMAN

ÇIKIŞ DÖĞÜMÜ



$$\begin{aligned} &= \text{Linear}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + w_{41} x_4 + b) \\ &= \text{Linear}(0.46 * 0.14 + 0.16 * 2.30 + -0.08 * 0.91 + 0.42 * 0.17 + 0.52) \\ &= \text{Linear}(0.06 + 0.36 + -0.07 + 0.07 + 0.52) \\ &= \text{Linear}(0.95) \\ &= 0.95 \end{aligned}$$

II. Düğümler ve Gizli Katmanlar

1. Model parametrelerini değiştirmeyi denesek ve gizli katman düğüm değerleri ve çıktı değeri üzerindeki etkisini gözlemlese, hesaplama denklemlerine baktığımızda bu model doğrusal olmayan özellikleri öğrenebilir mi?

Gizli katman
1. nöron

$$\begin{aligned} &= \text{Linear}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + b) \\ &= \text{Linear}(0.15 * 1.00 + 0.42 * 2.00 + -0.42 * 3.00 + 0.41) \\ &= \text{Linear}(0.15 + 0.84 + -1.26 + 0.41) \\ &= \text{Linear}(0.14) \\ &= 0.14 \end{aligned}$$

Gizli katman
2. nöron

$$\begin{aligned} &= \text{Linear}(w_{12} x_1 + w_{22} x_2 + w_{32} x_3 + b) \\ &= \text{Linear}(-0.07 * 1.00 + 0.31 * 2.00 + 0.50 * 3.00 + 0.25) \\ &= \text{Linear}(-0.07 + 0.62 + 1.50 + 0.25) \\ &= \text{Linear}(2.30) \\ &= 2.30 \end{aligned}$$

Gizli katman
3. nöron

$$\begin{aligned} &= \text{Linear}(w_{13} x_1 + w_{23} x_2 + w_{33} x_3 + b) \\ &= \text{Linear}(-0.35 * 1.00 + -0.07 * 2.00 + 0.26 * 3.00 + 0.63) \\ &= \text{Linear}(-0.35 + -0.14 + 0.77 + 0.63) \\ &= \text{Linear}(0.91) \\ &= 0.91 \end{aligned}$$

Gizli katman
4. nöron

$$\begin{aligned} &= \text{Linear}(w_{14} x_1 + w_{24} x_2 + w_{34} x_3 + b) \\ &= \text{Linear}(-0.43 * 1.00 + 0.48 * 2.00 + -0.16 * 3.00 + 0.12) \\ &= \text{Linear}(-0.43 + 0.96 + -0.47 + 0.12) \\ &= \text{Linear}(0.17) \\ &= 0.17 \end{aligned}$$

Çıkış
Düğümü

$$\begin{aligned} &= \text{Linear}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + w_{41} x_4 + b) \\ &= \text{Linear}(0.46 * 0.14 + 0.16 * 2.30 + -0.08 * 0.91 + 0.42 * 0.17 + 0.52) \\ &= \text{Linear}(0.06 + 0.36 + -0.07 + 0.07 + 0.52) \\ &= \text{Linear}(0.95) \\ &= 0.95 \end{aligned}$$

II. Düğümler ve Gizli Katmanlar

1. Cevabımız hayır olacaktır. Çünkü;
2. Gizli katmandaki hesaplamalarını incelersek, hepsinin doğrusal olduğunu (çarpma ve toplama işlemlerini içerir) görürüz.
3. Daha sonra çıktı düğümündeki hesaplamayı incelersek, bu hesaplamanın da doğrusal olduğunu görürüz.
4. Doğrusal hesaplamaların çıktısı üzerinde gerçekleştirilen doğrusal hesaplamalar da doğrusaldır, bu da bu modelin doğrusal olmayan ilişkileri öğrenemeyeceği anlamına gelir.

III. Aktivasyon (Etkinleştirme) İşlevleri

- 1. Önceki örneğimizde ağımıza sadece gizli katmanlar eklemenin doğrusal olmayan durumları temsil etmek için yeterli olmadığını gördük.**
- 2. Doğrusal işlemler üzerinde gerçekleştirilen doğrusal işlemler hep doğrusaldır.**
- 3. Peki değerler arasındaki doğrusal olmayan ilişkileri öğrenmek için bir sinir ağını nasıl yapılandırabiliriz?**
- 4. Doğrusal olmayan matematiksel işlemleri modele eklemenin bir yoluna ihtiyacımız var.**
- 5. Bunu biraz hatırlarsak, bunun nedeni aslında ilk derslerde doğrusal bir modelin çıktısına doğrusal olmayan matematiksel işlemler uygulamış olmamızdır.**
- 6. Lojistik Regresyon konusunda modelin çıktısını bir sigmoid fonksiyonundan geçirerek doğrusal bir regresyon modelini 0'dan 1'e (bir olasılığı temsil eden) sürekli bir değer çıktısı verecek şekilde uyarlamıştık.**
- 7. Aynı prensibi sinir ağımıza da uygulayabiliriz.**

I. Sinir Ağları


- 1. Aktivasyon fonksiyonu:** Bu fonksiyon, hücreye gelen net girdiyi işleyerek hücrenin bu girdiye karşılık üreteceği çıktıyı belirler.
- 2. Toplama fonksiyonunda olduğu gibi aktivasyon fonksiyonu olarak da çıktıyı hesaplamak içinde değişik formüller kullanılmaktadır.**
- 3. Bazı modeller (mesela çok katmanlı algılayıcı) bu fonksiyonun türevinin alınabilir bir fonksiyon olmasını şart koşmaktadır.**
- 4. Toplama fonksiyonunda olduğu gibi aktivasyon fonksiyonunda da ağın her bir sinir hücresinin (işleme birimi) hepsinin aynı fonksiyonu kullanması gerekmez.**

III. Aktivasyon (Etkinleştirme) İşlevleri

- 1. Bazı elemanlar aynı fonksiyonu diğerleri farklı fonksiyonları kullanabilirler.**
- 2. Bir problem için en uygun fonksiyonda yine tasarımcının denemeleri sonucunda belirleyebileceği bir durumdur.**
- 3. Uygun fonksiyonu gösteren bir formül bulunmuş değildir.**
- 4. Burada sinir ağı için bir aktivasyon fonksiyonunun görevi; değer, sinir ağının bir sonraki katmanının hesaplamalarına girdi olarak aktarılmadan önce bir nöronun çıktı değerinin doğrusal olmayan bir dönüşümünü sağlamasıdır.**
- 5. Sinir ağı modelinde bir aktivasyon fonksiyonu eklediğimizde, katman eklemenin daha fazla etkisi olduğunu görürüz.**

III. Aktivasyon (Etkinleştirme) İşlevleri

1. Şimdi sadece etkileşim fonksiyonunu doğrusal (linear) yerine sigmoid olarak kullanalım.




III. Aktivasyon (Etkinleştirme) İşlevleri

1. Şimdi sadece etkileşim fonksiyonunu doğrusal (linear) yerine sigmoid olarak kullanalım.

GİRİŞ DÜĞÜMLERİ

GİZLİ KATMAN

ÇIKIŞ DÜĞÜMÜ




III. Aktivasyon (Etkinleştirme) İşlevleri

1. Şimdi sadece etkileşim fonksiyonunu doğrusal (linear) yerine sigmoid olarak kullanalım.

GİRİŞ DÜĞÜMLERİ

GİZLİ KATMAN

ÇIKIŞ DÜĞÜMÜ




III. Aktivasyon (Etkinleştirme) İşlevleri

1. Şimdi sadece etkileşim fonksiyonunu doğrusal (linear) yerine sigmoid olarak kullanalım.

GİRİŞ DÜĞÜMLERİ

GİZLİ KATMAN

ÇIKIŞ DÜĞÜMÜ



III. Aktivasyon (Etkinleştirme) İşlevleri

1. Şimdi sadece etkileşim fonksiyonunu doğrusal (linear) yerine sigmoid olarak kullanalım.

GİRİŞ DÜĞÜMLERİ

GİZLİ KATMAN

ÇIKIŞ DÜĞÜMÜ

$x_1 = 1.00$
 $w_{14} = -0,38$

$x_2 = 2.00$
 $w_{24} = -0,1$

$x_3 = 3.00$
 $w_{34} = 0,04$

0.19

0.65

0.73

0.60
 $b = 0,85$

--

$$\begin{aligned} &= \text{Sigmoid}(w_{14} x_1 + w_{24} x_2 + w_{34} x_3 + b) \\ &= \text{Sigmoid}(-0.38 * 1.00 + -0.10 * 2.00 + 0.04 * 3.00 + 0.85) \\ &= \text{Sigmoid}(-0.38 + -0.20 + 0.13 + 0.85) \\ &= \text{Sigmoid}(0.41) \\ &= 0.60 \end{aligned}$$


III. Aktivasyon (Etkinleştirme) İşlevleri

1. Şimdi sadece etkileşim fonksiyonunu doğrusal (linear) yerine sigmoid olarak kullanalım.

GİRİŞ DÜĞÜMLERİ

GİZLİ KATMAN


ÇIKIŞ DÜĞÜMÜ



$$\begin{aligned} &= \text{Sigmoid}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + w_{41} x_4 + b) \\ &= \text{Sigmoid}(0.05 * 0.19 + 0.50 * 0.65 + 0.28 * 0.73 + -0.11 * 0.60 + 0.42) \\ &= \text{Sigmoid}(0.01 + 0.32 + 0.20 + -0.07 + 0.42) \\ &= \text{Sigmoid}(0.89) \\ &= 0.71 \end{aligned}$$


III. Aktivasyon (Etkinleştirme) İşlevleri

1. Şimdi sadece etkileşim fonksiyonunu doğrusal (linear) yerine sigmoid olarak kullanalım.




III. Aktivasyon (Etkinleştirme) İşlevleri

1. Giriş değerlerini doğrusal olmaktan çıkarsak bile etkileşim işlevi olarak sigmoid işlev kullandığımızda doğrusal olmayanlıkları doğrusal olmayanlıklar üzerine yığarak, girdiler ile tahmin edilen çıktılar arasındaki çok karmaşık ilişkileri modelleyebiliriz.




III. Aktivasyon (Etkinleştirme) İşlevleri

1. Kısaca, her katman ham girdiler üzerinde daha karmaşık, daha üst düzey bir fonksiyonu etkili bir şekilde öğrenmiş olur.



III. Aktivasyon (Etkinleştirme) İşlevleri


1. Etkileşim işlevi olarak yaygın şekilde kullanılan üç matematiksel işlev sigmoid, tanh ve ReLU'dur.
2. Sigmoid işlevi, x giriş üzerinde aşağıdaki dönüşümü gerçekleştirir ve 0 ile 1 arasında bir çıkış değeri üretir. $F(x) = \frac{1}{1 + e^{-x}}$
3. Sigmoid terimi genellikle herhangi bir S şeklindeki işlevi ifade etmek için daha genel olarak kullanılır. Belirli işlev için daha teknik olarak kesin bir terim lojistik işlevdir.



III. Aktivasyon (Etkinleştirme) İşlevleri


1. Tanh (kısaca "hiperbolik tanjant") işlevi, girdiyi dönüştürerek -1 ile 1 arasında bir çıktı değeri üretir:

$$F(x) = \tanh(x)$$



III. Aktivasyon (Etkinleştirme) İşlevleri

1. Düzeltmeli doğrusal birim etkileşim işlevi (Rectified Linear Unit Activation Function veya kısaca ReLU) çıktıyı aşağıdaki algoritmayı kullanarak dönüştürür:
 - a) Eğer giriş değeri 0'dan küçükse, 0 döndür.
 - b) Eğer giriş değeri 0'dan büyük veya eşitse, giriş değerini döndür.
2. ReLU, $\max()$ fonksiyonu kullanılarak matematiksel olarak temsil edilebilir: $F(x) = \max(0, x)$
3. ReLU, sinir ağı eğitimi sırasında azalan gradyan (gradient descent) sorununa daha az duyarlı olduğu için, sigmoid veya tanh gibi yumuşak bir işlevden daha iyi bir aktivasyon işlevi olarak çalışır.
4. ReLU'nun hesaplanması da bu işlevlerden çok daha kolaydır.



III. Aktivasyon (Etkinleştirme) İşlevleri

1. Pratikte, herhangi bir matematiksel işlev bir aktivasyon fonksiyonu olarak hizmet edebilir.
2. Aktivasyon işlevi olarak σ temsil ettiğini varsayalım.
3. Ağdaki bir düğümün değeri şu formülle verileceğini unutmayalım: $\sigma(w \cdot x + b)$
4. Keras makine öğrenmesi kütüphanesi, birçok aktivasyon işlevi için kullanıma hazır işlevler sunar.
5. Bazıları şu şekildedir¹; celu, elu, eksponansiyel, gelu, glu, hard_shrink, hard_sigmoid, hard_silu, hard_tanh, leaky_relu, log_sigmoid, log_softmax, mish, selu, silu
6. Ama tüm bunlara rağmen, ilk olarak ReLU ile başlanması her zaman tavsiye edilir.

1) <https://keras.io/api/layers/activations/>

III. Aktivasyon (Etkinleştirme) İşlevleri

1. Modelimiz, bir sinir ağından bahsedilirken genellikle kastedilen tüm standart bileşenlere sahiptir;
 - a) Nöronlara benzeyen, katmanlar halinde düzenlenmiş bir düğüm kümesi.
 - b) Her bir sinir ağı katmanı ile altındaki katman arasındaki bağlantıları temsil eden bir öğrenilmiş ağırlık ve önyargı kümesi. (Bunun altındaki katman başka bir sinir ağı katmanı veya başka bir tür katman olabilir.)
 - c) Bir katmandaki her düğümün çıktısını dönüştüren bir aktivasyon fonksiyonu. (Farklı katmanların farklı aktivasyon fonksiyonları olabilir.)
2. Dikkat edilmesi gereken konu da şudur; Bir sinir ağı her zaman özellik çaprazlamalarından daha iyi olmak zorunda değildir, ancak sinir ağıları birçok durumda iyi çalışan esnek bir alternatif sunar.

Kaynaklar

- 1) Yapay Öğrenme, Ethem ALPAYDIN
- 2) Understanding Machine Learning: From Theory to Algorithms, Shai Shalev-Shwartz, Shai Ben-David
- 3) https://developers-dot-devsite-v2-prod.appspot.com/machine-learning/crash-course/neural-networks/nodes-hidden-layers_674425a25c7df937f6e9b109e162a76b6bf55147a77a4b0681ceb90c89a26437.frame?hl=tr