

Makine Öğrenmesi

Ders 11



Bu Dersin İçeriği

I. Destek Vektör Makinaları – Support Vector Machines

I. Destek Vektör Makinaları

- ❑ Karmaşık bir model gerektiren büyük bir veri setimiz varsa, tam doğrusal regresyon veya lojistik regresyon hesaplama açısından çok maliyetlidir.
- ❑ Daha hızlı ama yine de iyi genelleme yapabilen bir frekansçı yöntem var mı?
- ❑ Ham girdilerden doğrudan cevabı tahmin etmeye çalışmak yerine, bir **özellik** katmanı çıkararak başlayabiliriz.
- ❑ Girdi değerlerinin belirli kombinasyonlarının yararlı olacağını zaten biliyorduk (örneğin, özellik çağrazlaması), ve bu mantıklıdır.

I. Destek Vektör Makinaları

- ❑ Özellikleri öğrenmek yerine, bunları elle tasarlayabiliriz.
- ❑ Elle kodlanan özellikler, öğrenilmesi gerekmeyen doğrusal olmayan nöron katmanına eşdeğerdir.
- ❑ İki sınıflı bir problem için çok büyük bir özellik kümesi kullanırsak, sınıflar neredeyse kesinlikle doğrusal olarak ayrılabilir olacaktır.
- ❑ Ancak doğrusal ayırıcı kesinlikle zayıf bir genelleme sağlayacaktır.

I. Destek Vektör Makinaları

- ❑ Ön işleme özenle tasarlanmış özellikler oluşturmaktır.
- ❑ Peki makine öğrenmesi için bu bir hile midir?
- ❑ Özenle tasarlanmış, göreve özel, elle kodlanmış özellikler kullanıp ardından öğrenme algoritmasının tüm sorunu çözdüğünü iddia edersek bu hiledir.
- ❑ Çünkü ön işleme sonrası oluşan özellikler gerçek dünyadaki özellikler gibi değildir.

I. Destek Vektör Makinaları

- ❑ Asıl zor olan kısım özellikleri tasarlamaktır.
- ❑ Doğrusal olmayan ön işleme bu hileyi ortadan kaldırabilir.
- ❑ Doğrusal olmayan öğrenme için sinir ağlarında geri yayılım örnek verebiliriz ancak bu çok daha zor ve çok daha karmaşıktır.
- ❑ Bu nedenle göreve bağlı olmayan çok büyük bir doğrusal olmayan özellikler kümesi kullanırsak gerçek dünya özelliklerini temsil etmiş oluruz.
- ❑ Destek Vektör Makineleri bunu yapar.

I. Destek Vektör Makinaları

- ❑ Destek Vektör Makineleri (Support Vector Machines-SVM'ler), verileri analiz eden ve kalıpları tanıyan, sınıflandırma ve regresyon analizi için kullanılan, ilişkili öğrenme algoritmalarına sahip denetimli öğrenme modelleridir.
- ❑ Bir SVM modeli, örneklerin uzayda noktalar olarak temsil edilmesidir; ayrı kategorilerin örnekleri, mümkün olduğunca geniş bir boşlukla ayrılacak şekilde eşleştirilir.
- ❑ Yeni örnekler daha sonra aynı uzaya eşleştirilir ve boşluğun hangi tarafında yer aldıklarına göre bir kategoriye ait oldukları tahmin edilir.


I. Destek Vektör Makinaları

- ❑ Neden SVM?
- ❑ Kullanımı kolaydır.
- ❑ Genellikle iyi genelleme performansı gösterir.
- ❑ Aynı algoritma, çok az ayarlamayla çeşitli sorunları çözer.
- ❑ Aşırı uyumu (overfitting) önlemek için akıllı bir yöntemleri vardır.
- ❑ Gerekli görünen kadar hesaplama gerektirmeden çok sayıda özelliği kullanmak için çok akıllı bir yöntemleri vardır (dersin ikinci yarısı).

I. Destek Vektör Makinaları


- ❑ **Giriş:** Perceptron yeniden ele alalım ve Doğrusal Ayırıcıları hatırlayalım;
- ❑ İkili sınıflandırma, özellik uzayında sınıfları ayırma görevi olarak

görülebilir:




I. Destek Vektör Makinaları

□ En iyi doğrusal ayırıcıyı nasıl bulacağız.




I. Destek Vektör Makinaları

□ En iyi doğrusal ayırıcıyı nasıl bulacağız.




I. Destek Vektör Makinaları

□ En iyi doğrusal ayırıcıyı nasıl bulacağız.




I. Destek Vektör Makinaları

- ❑ Örnek $\mathbf{x}_i$ ile ayırıcı arasındaki mesafeyi tanımlayalım: $r = \frac{\mathbf{w}^T \mathbf{x}_i + b}{\|\mathbf{w}\|}$
- ❑ Hiperdüzleme (şimdilik çizgi) en yakın örnekler **destek vektörleridir**.
- ❑ Destek vektörlerin marjı ρ , destek vektörleri arasındaki mesafedir.



I. Destek Vektör Makinaları

- İki sınıftan alınan örneklerle eğitilmiş bir SVM için maksimum marj hiper düzlemi ve diğer marjlar.



I. Destek Vektör Makinaları

- ❑ **Maksimum Marj Sınıflandırması:** Marjı (aralık da diyebiliriz.) maksimize etmek sezgisel olarak ve PAC (Probably Approximately Correct (Muhtemelen Yaklaşık Doğru) teorisine göre iyidir.
- ❑ PAC öğrenme teorisi, Leslie Valiant tarafından ortaya atılan bir çerçevedir ve bir öğrenme algoritmasının gerçek hayatta ne kadar **iyi genelleme** yapabileceğini matematiksel olarak açıklar.
- ❑ Bu durum yalnızca destek vektörlerinin önemli olduğunu; diğer eğitim örneklerinin göz ardı edilebileceğini ima eder.

I. Destek Vektör Makinaları

- ❑ Doğrusal DVM: Eğitim kümesi $\{(\mathbf{x}_i, y_i)\}_{i=1..n}$, $\mathbf{x}_i \in \mathbf{R}^d$, $y_i \in \{-1, 1\}$ bir marjin ρ ile bir hiper düzlem tarafından ayrılıyor olsun.
- ❑ O zaman her bir eğitim örneği $(\mathbf{x}_i, y_i)$ için:
$$\begin{aligned} \mathbf{w}^T \mathbf{x}_i + b &\leq -\rho/2 & \text{if } y_i = -1 \\ \mathbf{w}^T \mathbf{x}_i + b &\geq \rho/2 & \text{if } y_i = 1 \end{aligned} \quad \Leftrightarrow \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq \rho/2$$
- ❑ Her bir destek vektörü $\mathbf{x}_s$ için yukarıdaki eşitsizlik bir eşitliktir.
 $\mathbf{w}$ ve b , eşitlikte $\rho/2$ ile yeniden ölçeklendirildikten sonra, her bir $\mathbf{x}_s$ ile hiper düzlem arasındaki mesafe tanılanır:
$$r = \frac{y_s(\mathbf{w}^T \mathbf{x}_s + b)}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$
- ❑ Böylece marjin, (yeniden ölçeklendirilmiş) $\mathbf{w}$ ve b cinsinden şu şekilde ifade edilebilir: $\rho = 2r = \frac{2}{\|\mathbf{w}\|}$

I. Destek Vektör Makinaları

- Ardından, ikinci dereceden optimizasyon problemini şu şekilde formüle edebiliriz:

w ve **b** değerlerini, $\rho = \frac{2}{\|\mathbf{w}\|}$ maksimize edilecek şekilde bulalım.

Ve hepsi için $(\mathbf{x}_i, y_i), i=1..n$: $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ sağlasın.

- Bu, şu şekilde yeniden formüle edilebilir:

w ve **b** değerlerini

$\Phi(\mathbf{w}) = \|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w}$ en küçük yapacak (optimize edecek) şekilde bulun.

Ve tüm örnekler için $(\mathbf{x}_i, y_i), i=1..n$: $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ sağlasın

I. Destek Vektör Makinaları

- ❑ Bu, durumda doğrusal kısıtlamalara tabi bir ikinci dereceden fonksiyonu optimize etmek gerekiyor.

$\mathbf{w}$ ve b değerlerini

$\Phi(\mathbf{w}) = \|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w}$ en küçük yapacak şekilde bulalım.

Ve tüm örnekler için $(\mathbf{x}_i, y_i)$, $i=1..n$: $y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ sağlasın

- ❑ İkinci dereceden optimizasyon problemleri, birkaç (önemsiz olmayan) algoritmanın mevcut olduğu, iyi bilinen bir matematiksel programlama problemi sınıfıdır.

I. Destek Vektör Makinaları

- Çözüm, *Lagrange çarpanı* α_i 'nin birincil (orijinal) problemdeki her eşitsizlik kısıtlamasıyla ilişkilendirildiği bir ikili problem oluşturmayı içerir:

$\alpha_1 \dots \alpha_n$ şöyle bulunur;

$Q(\alpha) = \sum \alpha_i - \frac{1}{2} \sum \sum \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$ maksimize edilmeli ve


(1) $\sum \alpha_i y_i = 0$ olmalı

(2) Her α_i için $\alpha_i \geq 0$ şartı sağlanmalı

I. Destek Vektör Makinaları

❑ İkili problemin çözümü $\alpha_1 \dots \alpha_n$ verildiğinde, birincil problemin çözümü şöyledir: Herhangi bir $\alpha_k > 0$ ise $\mathbf{w} = \sum \alpha_i y_i \mathbf{x}_i$ ve $b = y_k - \sum \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_k$

❑ Sıfır olmayan her α_i , karşılık gelen $\mathbf{x}_i$ 'nin bir destek vektörü olduğunu gösterir.



I. Destek Vektör Makinaları

- ❑ O zaman sınıflandırma fonksiyonu şöyledir ($\mathbf{w}$ 'ye açıkça ihtiyaç duymadığımızı unutmayın):

$$f(\mathbf{x}) = \sum \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$$


- ❑ Bunun, test noktası $\mathbf{x}$ ile destek vektörleri $\mathbf{x}_i$ – arasındaki iç çarpıma dayandığını unutmayın.
- ❑ Ayrıca, optimizasyon problemini çözmenin tüm eğitim noktaları arasındaki iç çarpımları $\mathbf{x}_i^T \mathbf{x}_j$ hesaplamayı içerdiğini de unutmayın.

I. Destek Vektör Makinaları

- ❑ **Esnek-Yumuşak Marj Sınıflandırması(Soft Margin Classification):** Eğitim kümesi doğrusal olarak ayrılabilir değilse ne olur?
- ❑ Zor veya gürültülü örneklerin yanlış sınıflandırılmasına izin vermek için gevşek (slack) değişkenler ξ_i eklenebilir, bu da yumuşak-esnek marj olarak adlandırılır.

I. Destek Vektör Makinaları

- ❑ Zor veya gürültülü örneklerin yanlış sınıflandırılmasına izin vermek için gevşek (slack) değişkenler ξ_i eklenebilir, bu da yumuşak-esnek marj olarak adlandırılır.



I. Destek Vektör Makinaları

- ❑ Eski formülasyona bakalım:

$\mathbf{w}$ ve b değerlerini

$\Phi(\mathbf{w}) = \|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w}$ en küçük yapacak şekilde bulun.

Ve tüm örnekler için $(\mathbf{x}_i, y_i), i=1..n$: $y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ sağlasın

- ❑ Değiştirilmiş formülasyon gevşek değişkenleri içerir:

$\mathbf{w}$ ve b değerlerini

$\Phi(\mathbf{w}) = \mathbf{w}^T \mathbf{w} + C \sum \xi_i$ en küçük yapacak şekilde bulun

Ve tüm örnekler için $(\mathbf{x}_i, y_i), i=1..n$:

$y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$, $\xi_i \geq 0$ sağlasın.

- ❑ Parametre C, aşırı uyumu kontrol etmenin bir yolu olarak görülebilir: marjı maksimize etmek ile eğitim verilerini uydurmak arasındaki *göreceli önemi* “takas eder”.

I. Destek Vektör Makinaları

- ❑ İkili problem, ayrılabilir durumla aynıdır (eğer gevşek değişkenler $C\Sigma\xi_i^2$ için 2-norm cezası birincil hedefte kullanılmış olsaydı, gevşek değişkenler için ek Lagrange çarpanlarına ihtiyaç duyulurdu):

$\alpha_1 \dots \alpha_n$ şöyle bulunur;

$\mathbf{Q}(\alpha) = \Sigma \alpha_i - \frac{1}{2} \Sigma \Sigma \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$ maksimize edilmeli ve

(1) $\Sigma \alpha_i y_i = 0$ olmalı

(2) Her α_i için $0 \leq \alpha_i \leq C$ şartı sağlanmalı

- ❑ Yine, sıfır olmayan α_i ile $\mathbf{x}_i$ destek vektörleri olacaktır.

- ❑ İkili problemin çözümü şöyledir:

$$\mathbf{w} = \Sigma \alpha_i y_i \mathbf{x}_i$$

$$b = y_k(1 - \xi_k) - \Sigma \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_k \quad \text{herhangi bir } k \text{ nıncı için } \alpha_k > 0$$

Yine, sınıflandırma için $\mathbf{w}$ 'yi açıkça hesaplamamız gerekmez:

$$f(\mathbf{x}) = \Sigma \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$$

I. Destek Vektör Makinaları

- ❑ **Maksimum Marjlar için Teorik Gerekçe:** Vapnik (Vladimir Vapnik) aşağıdakileri kanıtlamıştır:
- ❑ Optimal doğrusal ayırıcıların sınıfı, VC (Vapnik–Chervonenki) boyutu h yukarıdan sınırlıdır.

$$h \leq \min \left\{ \left\lceil \frac{D^2}{\rho^2} \right\rceil, m_0 \right\} + 1$$

- ❑ burada ρ marj, D tüm eğitim örneklerini kapsayabilecek en küçük kürenin çapı ve m_0 boyutluluktur.

I. Destek Vektör Makinaları

❑ Maksimum Marjlar için Teorik Gerekçe:

$$h \leq \min \left\{ \left\lceil \frac{D^2}{\rho^2} \right\rceil, m_0 \right\} + 1$$

- ❑ Sezgisel olarak bu, boyutluluk m_0 'dan bağımsız olarak marj ρ 'yi maksimize ederek VC boyutunu minimize edebileceğimiz anlamına gelir.
- ❑ Böylece, sınıflandırıcının karmaşıklığı boyutluluktan bağımsız olarak düşük tutulur.

I. Destek Vektör Makinaları

❑ Özet:


- ❑ Sınıflandırıcı, ayırıcı bir hiperdüzlemdir (hyperplane).
- ❑ En “önemli” eğitim noktaları destek vektörleridir; bunlar hiperdüzlemi tanımlar.
- ❑ Kare optimizasyon algoritmaları, hangi eğitim noktaları $\mathbf{x}_i$ 'nin sıfır olmayan Lagrange çarpanları α_i ile destek vektörleri olduğunu belirleyebilir.
- ❑ Hem problemin ikili formülasyonunda hem de çözümde eğitim noktaları yalnızca iç çarpımların içinde görünür:

$$\begin{aligned} \mathbf{w} &= \sum \alpha_i y_i \mathbf{x}_i \\ b &= y_k(1 - \xi_k) - \sum \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_k \quad \text{herhangi bir } k \\ &\text{nıncı için } \alpha_k > 0 \end{aligned}$$


$$f(\mathbf{x}) = \sum \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$$

I. Destek Vektör Makinaları

- ❑ **Doğrusal Olmayan DVM:** Biraz gürültü içeren doğrusal olarak ayrılabilir veri kümeleri harika sonuçlar verir:




- ❑ Peki, veri kümesi çok zor ise ne yapacağız?




I. Destek Vektör Makinaları

□ Verileri daha yüksek boyutlu bir uzaya eşlemek nasıl olur?



I. Destek Vektör Makinaları

- **Genel fikir:** Orijinal özellik uzayı her zaman, eğitim kümesinin ayrılabilir olduğu daha yüksek boyutlu bir özellik uzayına eşlenebilir:



I. Destek Vektör Makinaları

- ❑ **Çekirdek Hilesi (Kernel Trick):** Doğrusal sınıflandırıcı, vektörler arasındaki iç çarpıma dayanır; $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$
- ❑ Her veri noktası, bir dönüşüm $\Phi: \mathbf{x} \rightarrow \phi(\mathbf{x})$, aracılığıyla yüksek boyutlu uzaya eşlenirse, iç çarpım şu şekilde olur:
$$K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$
- ❑ Çekirdek fonksiyonu, bazı özellik uzaylarında iç çarpıma eşdeğer bir fonksiyondur.
- ❑ Örnek:
- ❑ 2 boyutlu vektörler $\mathbf{x} = [x_1 \ x_2]$; ve çekirdek $K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^T \mathbf{x}_j)^2$, olsun,
- ❑ $K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$: olduğunu göstermek gerekir:

I. Destek Vektör Makinaları

□ Şöyle ki;

$$\begin{aligned} K(\mathbf{x}_i, \mathbf{x}_j) &= (1 + \mathbf{x}_i^T \mathbf{x}_j)^2, \\ &= 1 + x_{i1}^2 x_{j1}^2 + 2 x_{i1} x_{j1} x_{i2} x_{j2} + x_{i2}^2 x_{j2}^2 + 2 x_{i1} x_{j1} + 2 x_{i2} x_{j2} \\ &= [1 \ x_{i1}^2 \ \sqrt{2} x_{i1} x_{i2} \ x_{i2}^2 \ \sqrt{2} x_{i1} \ \sqrt{2} x_{i2}]^T [1 \ x_{j1}^2 \ \sqrt{2} x_{j1} x_{j2} \ x_{j2}^2 \ \sqrt{2} x_{j1} \ \sqrt{2} x_{j2}] \\ &= \boldsymbol{\varphi}(\mathbf{x}_i)^T \boldsymbol{\varphi}(\mathbf{x}_j), \quad \text{iken} \quad \boldsymbol{\varphi}(\mathbf{x}) = [1 \ x_1^2 \ \sqrt{2} x_1 x_2 \ x_2^2 \ \sqrt{2} x_1 \ \sqrt{2} x_2] \text{ olur.} \end{aligned}$$

□ Böylece, bir çekirdek fonksiyonu verileri yüksek boyutlu bir uzaya örtük olarak eşler (her $\boldsymbol{\varphi}(\mathbf{x})$ değerini açıkça hesaplamaya gerek kalmadan).

I. Destek Vektör Makinaları

- ❑ Peki çekirdek fonksiyonları nelerdir?
- ❑ Bazı fonksiyonlar $K(\mathbf{x}_i, \mathbf{x}_j)$ için $K(\mathbf{x}_i, \mathbf{x}_j) = \varphi(\mathbf{x}_i)^T \varphi(\mathbf{x}_j)$ kontrolü zahmetli olabilir.
- ❑ Mercer teoremi:

Her yarı pozitif kesin simetrik fonksiyon bir çekirdektir.

- ❑ Yarı pozitif kesin simetrik fonksiyonlar, yarı pozitif kesin simetrik Gram matrisine karşılık gelir:

K=

$K(\mathbf{x}_1, \mathbf{x}_1)$	$K(\mathbf{x}_1, \mathbf{x}_2)$	$K(\mathbf{x}_1, \mathbf{x}_3)$	...	$K(\mathbf{x}_1, \mathbf{x}_n)$
$K(\mathbf{x}_2, \mathbf{x}_1)$	$K(\mathbf{x}_2, \mathbf{x}_2)$	$K(\mathbf{x}_2, \mathbf{x}_3)$		$K(\mathbf{x}_2, \mathbf{x}_n)$
...	...	...	...	...
$K(\mathbf{x}_n, \mathbf{x}_1)$	$K(\mathbf{x}_n, \mathbf{x}_2)$	$K(\mathbf{x}_n, \mathbf{x}_3)$	...	$K(\mathbf{x}_n, \mathbf{x}_n)$

I. Destek Vektör Makinaları

❑ Örnek Çekirdek Fonksiyonları:

❑ Doğrusal: $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$, Eşleme $\Phi: \mathbf{x} \rightarrow \boldsymbol{\varphi}(\mathbf{x})$, burada $\boldsymbol{\varphi}(\mathbf{x})$ x'in kendisidir.

❑ p kuvvetli polinom: $K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^T \mathbf{x}_j)^p$

-Eşleme $\Phi: \mathbf{x} \rightarrow \boldsymbol{\varphi}(\mathbf{x})$, burada $\boldsymbol{\varphi}(\mathbf{x}) \binom{d+p}{p}$ boyutlara sahiptir

❑ Gauss (radyal baz fonksiyonu): $K(\mathbf{x}_i, \mathbf{x}_j) = \frac{e^{-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}}}{e}$

-Eşleme $\Phi: \mathbf{x} \rightarrow \boldsymbol{\varphi}(\mathbf{x})$, burada $\boldsymbol{\varphi}(\mathbf{x})$ sonsuz boyutludur: her nokta bir a fonksiyona (bir Gauss) eşlenir; destek vektörleri için fonksiyonların kombinasyonu ayırıcıdır.

❑ Yüksek boyutlu uzay hala içsel boyutluluk d 'ye sahiptir (eşleme *tam* değildir), ancak içindeki doğrusal ayırıcılar orijinal uzaydaki *doğrusal olmayan* ayırıcılarla karşılık gelir.

I. Destek Vektör Makinaları

- Çift problem formülasyonu:

$\alpha_1 \dots \alpha_n$ şöyle bulunur;

$\mathbf{Q}(\boldsymbol{\alpha}) = \sum \alpha_i - \frac{1}{2} \sum \sum \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$ maksimize edilmeli ve

(1) $\sum \alpha_i y_i = 0$ olmalı

(2) Her α_i için $\alpha_i \geq 0$ şartı sağlanmalı

- Çözüm şöyledir:

$$f(\mathbf{x}) = \sum \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}_j) + b$$

- α_i 'leri bulmak için optimizasyon teknikleri aynı kalır!

I. Destek Vektör Makinaları

□ Temel Algoritma:

1. Bir çekirdek fonksiyonu seçin.
2. C için bir değer seçin.
3. İkinci dereceden programlama problemini çözün (birçok yazılım paketi mevcuttur).
4. Destek vektörlerinden ayırt edici fonksiyonu oluşturun.

I. Destek Vektör Makinaları

- ❑ Bazı Meseleler;
- ❑ Çekirdek seçimi: Gauss veya polinom çekirdek varsayılan seçenektir
 - Etkili değilse, daha ayrıntılı çekirdekler gerekir
 - Alan uzmanları (verinin niteliğine hakim), uygun benzerlik ölçütlerinin formüle edilmesinde yardımcı olabilir.
- ❑ Çekirdek parametrelerinin seçimi: ör. σ olan bir Gauss çekirdeğinde - σ , farklı sınıflandırmalara sahip en yakın noktalar arasındaki mesafedir. Güvenilir kriterlerin bulunmaması durumunda, uygulamalar bu tür parametreleri ayarlamak için doğrulama seti veya çapraz doğrulama kullanır.
- ❑ Optimizasyon kriteri – Sert marj v.s. Yumuşak marj - çeşitli parametrelerin test edildiği uzun bir dizi deney

I. Destek Vektör Makinaları

- ❑ SVM'ler ilk olarak 1992 yılında Boser, Guyon ve Vapnik tarafından önerilmiş ve 1990'ların sonlarında giderek popülerlik kazanmıştır.
- ❑ SVM'ler şu anda metinden genomik verilere kadar birçok sınıflandırma görevinde en iyi performans gösteren yöntemler arasındadır.
- ❑ SVM'ler, bu tür veriler için çekirdek fonksiyonları tasarlayarak özellik vektörlerinin ötesindeki karmaşık veri türlerine (ör. grafikler, diziler, ilişkisel veriler) uygulanabilir.

I. Destek Vektör Makinaları

- ❑ SVM teknikleri, regresyon [Vapnik et al. '97], temel bileşen analizi [Schölkopf et al. '99] vb. gibi birçok göreve genişletilmiştir.
- ❑ SVM'ler için en popüler optimizasyon algoritmaları, bir seferde α_i 'lerin bir alt kümesini tırmanma algoritması (hill-climbing) için *ayrıştırma* (*decomposition*) kullanır.

Kaynaklar

- 1) Yapay Öğrenme, Ethem ALPAYDIN
- 2) Understanding Machine Learning: From Theory to Algorithms, Shai Shalev-Shwartz, Shai Ben-David
- 3) Schölkopf, B., Williamson, R. C., Smola, A., Shawe-Taylor, J., & Platt, J. (1999). Support vector method for novelty detection. *Advances in neural information processing systems*, 12.
- 4) Müller, K. R., Smola, A. J., Rätsch, G., Schölkopf, B., Kohlmorgen, J., & Vapnik, V. (1997, October). Predicting time series with support vector machines. In *International conference on artificial neural networks* (pp. 999-1004). Berlin, Heidelberg: Springer Berlin Heidelberg.