

Makine Öğrenmesi

Ders 12




Bu Dersin İçeriği

I. Karar Ağaçları (Decision Tree)

I. Karar Ağaçları

- ❑ Karar Ağacı Nedir?
- ❑ Karar Ağacı Özellikleri
- ❑ Karar Ağacı Çalışma Algoritması
- ❑ Avantajları
- ❑ Dezavantajları
- ❑ Örnek Çalışmalar

My Cat's Decision-Making Tree.



I. Karar Ağaçları


- ❑ Karar ağaçları Morgan ve Sonquist tarafından Michigan Üniversitesi'nde 1970'li yılların başlarında kullanılan AID (Automatic Detector) karar ağacı ilk algoritma ve yazılımdır.
- ❑ Bu yöntem 60 yılı aşkın süredir kullanımdadır.

I. Karar Ağaçları

- ❑ Karar ağacı ağaç yapısı şeklinde sınıflandırıcı algoritmasıdır.
- ❑ Karar Ağaçları tümevarımlı mantığın programlama ortamına taşındığı basit fakat çok yaygın bir metottur.
- ❑ Ayrık değerli parametrelerle çalışır.
- ❑ Gürültüye karşı dayanıklı bir algoritmadır.
- ❑ C4.5 karar ağacı algoritması ailesi içinde en popüler algoritmadır.
- ❑ Karar ağacı algortimalarının dayandığı tüme varımlı felsefeye dair temel sezgi öğrenme özellikleriyle oluşturulacak karar ağacının olabildiğince küçük olmasının iyi olcağı yönündedir.

I. Karar Ağaçları

- ❑ İç Karar Düğümleri: Giriş verilerinin test edildiği, soruların sorulduğu ve hangi yöne yöneleceklerini belirleyen karar düğümleri
- ❑ Dal: Bu soruların cevaplarını temsil eder
- ❑ Uç Yapraklar: Kategorin bulunduğu sınıf etiketleri .




I. Karar Ağaçları

Kategori,
Etiket

Özellikler


Outlook	Temp.	Humidity	Windy	Play Golf
Rainy	Hot	High	False	No
Rainy	Hot	High	True	No
Overcast	Hot	High	False	Yes
Sunny	Mild	High	False	Yes
Sunny	Cool	Normal	False	Yes
Sunny	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Rainy	Mild	High	False	No
Rainy	Cool	Normal	False	Yes
Sunny	Mild	Normal	False	Yes
Rainy	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Sunny	Mild	High	True	No



(1) Hangisinden Başla? (root)


(2) Hangi Düğümden Devam Edeceksin?

(3) Ne zaman Duracaksın/ Sonuca Ulaşacaksın?




□ Bu karar ağacı maçı kazanır mıyız / kaybeder miyiz? sorusuna cevap veren bir sınıflandırma ağacıdır.

Yeşil-sarı kutular özellik (feature) düğümleri, kırmızı/beyaz kutular ise sonuç (sınıf) – Won/Lost düğümlerini ifade eder.



- ❑ Ağacı kökten yapraklara doğru sözle gezelim:
- ❑ 1. Kök düğüm: When (Maçın saati)
- ❑ En üstteki yeşil düğüm When:
 - 5pm, soldaki alt ağaç
 - 7pm, ortadaki alt ağaç
 - 9pm, doğrudan sonuç: Lost (bu saatte oynanırsa her durumda kaybediliyor)




❑ 2. düğüm Saat 5pm ise: Fred Starts (Fred Başlar mı)?

5pm dalında ikinci düğüm:

Sarı kutu: Fred Starts (Fred oyuna ilk beş / ilk 11'de başlıyor mu?)

Dalları: Yes olursa yaprak Lost olur. Yani maç 5'te ve Fred oyuna başlıyorsa sonuç kaybeder.

No olursa yeni özellik oluşur. JoeDefense (Joe Defansta)



□ JoeDefense (5pm, Fred başlamıyorsa dan geldik)

Bu düğümde Joe'nun savunmadaki pozisyonu soruluyor:

- Center olursa yaprak: Lost
- Forward olursa yaprak: Won

Yani:

- 5pm, Fred başlamaz, Joe savunmada Center oynarsa Lost
- 5pm, Fred başlamaz, Joe savunmada Forward oynarsa Won

Ağacın detaylı çözümü Karar Ağacı-Maç Kazanma Kaybetme.pdf dosyasındadır.



Özellikleri

- ❑ Danışmalı öğrenme (Supervised learning) algoritması
- ❑ Kullanımı neden yaygındır?
 - Ürettikleri kuralların kolay anlaşılır olması
 - Kolay uygulanabilir olmaları
 - Hem kategorik hem de sayısal verileri işleyebilirler


Algortimanın Adımları

- ❑ 1-Her öznitelik üzerinde bölme için bilgi kazancını hesapla(entropy(variance) azalma).
- ❑ 2-Yeni bir düğüm için en fazla bilgi kazancını veren özniteliği seç.
- ❑ 3-Bu özniteliğe dayalı olması eğitim verisini böl.
- ❑ 4-Alt düğümlere kadar hepsi için (Adım 1=>3) özyinelemeli olarak işlemi yineleyin.



Algortimanın Adımları



Algortimanın Adımları



Algortimanın Adımları



Karar Ağaçlarında Karar Düğümlerini Oluşturacak En İyi Nitelik Neden Seçilir?

- ❑ Kök düğümde ağacın dengeli bir şekilde dallanması ve sınıflandırma algoritmasının verimli olması için özellikler içinden en uygun olanı seçilir.
- ❑ Kök düğüm için uygulanan algoritma iç karar düğümleri içinde söz konusudur.

Karar Ağaçlarında Karar Düğümlerini Oluşturacak En İyi Nitelik Nasıl Seçilir?

- Shannon ve Weaver tarafından ilk defa tanımlanan Enformasyon Teorisi ile bütün sistemdeki beklenen değeri hesaplayabiliyoruz.



Claude Elwood Shannon



Warren Weaver


Entorpi

- ❑ $p_1, p_2, \dots, p_m$ toplamaları 1 olan olasılıklar.
- ❑ örnekler aynı sınıfa aitse $entropi = 0$
- ❑ örnekler sınıflar arasında eşit dağılmışsa $entropi = 1$
- ❑ örnekler sınıflar arasında rastgele dağılmışsa $0 < entropi < 1$
- ❑ Entropi formülü

$$E(S) = \sum_{i=0}^C -p_i * \log_2(p_i)$$
$$= -p(P)\log_2 p(P) - p(N)\log_2 p(N)$$

Entorpi

Entropi formülü



The diagram shows the entropy formula $E(S) = \sum_{i=0}^C -p_i * \log_2(p_i)$ on a green background. Three blue arrows point from text labels to parts of the formula: 'Hepsinin toplamı' points to the summation symbol, 'Olayın olasılığı' points to p_i , and 'Olayın sürprizi' points to $\log_2(p_i)$.

Hepsinin toplamı

Olayın olasılığı

Olayın sürprizi

$$E(S) = \sum_{i=0}^C -p_i * \log_2(p_i)$$

Information Gain(Bilgi Kazancı)

- ❑ Bilgi kazancı entropide ki beklenen azalmayı ölçer.
- ❑ Bu şekilde bizim için uygun olan özellik seçimini gerçekleştirebiliyoruz.

Bilgi Kazancı = Sistemin Enformasyon Değeri – Özelliğin Enformasyon Değeri

Örnek:

V1	V2	S
A	C	E
B	C	F
B	D	E
B	D	F

Sınıf Entropisi

$$H(S) = -\left(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{2}\log_2 \frac{1}{2}\right) = 1$$

V1 Entropisi

$$\begin{aligned} H(V1) &= \frac{1}{4}H(A) + \frac{3}{4}H(B) \\ &= \frac{1}{4}0 - \frac{3}{4}\left(\frac{1}{3}\log_2 \frac{1}{3} + \frac{2}{3}\log_2 \frac{2}{3}\right) \\ &= 0 + \frac{3}{4}0,9183 = 0,6887 \end{aligned}$$

V2 Entropisi

$$H(V2) = \frac{1}{2}H(C) + \frac{1}{2}H(D) = \frac{1}{2} + \frac{1}{2} = 1$$

$$H(S) - H(V1) \text{ ise } 1 - 0.6887 = 0.3113$$

$$H(S) - H(V2) \text{ ise } 1 - 1 = 0$$

✓ V1 Seçilir.


Karar Ağaçları: Hafta Sonu Örneği

- 1. Adım: Veri setinden öğrenme kümesi (train set) oluşturulur.

Weekend (Example)	Weather	Parents	Money	Decision (Category,Label)
W1	Sunny	Yes	Rich	Cinema
W2	Sunny	No	Rich	Tennis
W3	Windy	Yes	Rich	Cinema
W4	Rainy	Yes	Poor	Cinema
W5	Rainy	No	Rich	Stay in
W6	Rainy	Yes	Poor	Cinema
W7	Windy	No	Poor	Cinema
W8	Windy	No	Rich	Shopping
W9	Windy	Yes	Rich	Cinema
W10	Sunny	No	Rich	Tennis

Karar Ağaçları: Hafta Sonu Örneği

- 2. Adım: Veri setindeki en ayırt edici nitelik belirlenir ve ağacın kökü olarak alınır.



- 3. Adım: Ağacın çocuk düğümü olan A düğümüne ait alt veri kümesi belirlenir.

Weekend (Example)	Weather	Parents	Money	Decision (Category)
W1	Sunny	Yes	Rich	Cinema
W2	Sunny	No	Rich	Tennis
W10	Sunny	No	Rich	Tennis

Hafta sonu Örneği: Entropy

- Hafta sonu veri kümesindeki 10 örnekten
 - 6 örnek için karar sinema
 - 2 örnek için karar tenis oynamak
 - 1 örnek için karar evde kalmak ve
 - 1 örnek için karar alışverişe gitmek olduğuna göre

□ Entropy:

$$H(T) = - (6/10) \log_2(6/10) - (2/10) \log_2(2/10) - (1/10) \log_2(1/10) - (1/10) \log_2(1/10)$$

$$H(S) = 1,571$$

Hafta sonu Örneği: Bilgi Kazancı

□ Gain(weather)= ?

- Sunny=3 (1 Cinema, 2 Tennis)
- Windy=4 (3 Cinema, 1 Shopping)
- Rainy=3 (2 Cinema, 1 Stay in)

$$Entropy(Trainy) = - \left(\frac{2}{3}\right) \log_2 \left(\frac{2}{3}\right) - \left(\frac{1}{3}\right) \log_2 \left(\frac{1}{3}\right) = 0,918$$

$$Entropy(Twindy) = - \left(\frac{3}{4}\right) \log_2 \left(\frac{3}{4}\right) - \left(\frac{1}{4}\right) \log_2 \left(\frac{1}{4}\right) = 0,811$$

$$Entropy(Tsunny) = - (1/3) \log_2 (1/3) - (2/3) \log_2 (2/3) = 0,918$$

Hafta sonu Örneği :Bilgi Kazancı

$$\text{Gain}(\text{weather}) = \text{Entropy}(T) - ((P(\text{sunny})\text{Entropy}(T_{\text{sunny}}) + P(\text{windy}) \text{Entropy}(T_{\text{windy}}) + P(\text{rainy})$$

$$= 1,571 - ((3/10) * \text{Entropy}(T_{\text{sunny}}) + (4/10) * \text{Entropy}(T_{\text{windy}}) + (3/10) * \text{Entropy}(T_{\text{rainy}}))$$

$$= 1,571 - (0,3 * 0,918 + 0,4 * 0,811 + 0,3 * 0,918)$$

$$\text{Gain}(T, \text{weather}) = 0.6958 \approx 0,70$$

Hafta sonu Örneği :Bilgi Kazancı

□ Gain(T, parents)= ?

- Yes=5 (5 Cinema)
- No =5 (2 Tennis, 1 Cinema, 1 Shopping, 1 Stay in)

$$Entropy(Tyes) = - \left(\frac{5}{5}\right) \log_2 \left(\frac{5}{5}\right) = 0$$

$$Entropy(Tno) = - \left(\frac{2}{5}\right) \log_2 \left(\frac{2}{5}\right) - 3 \left(\frac{1}{5}\right) \log_2 \left(\frac{1}{5}\right) = 1,922$$

$$Gain(T, parents) = Entropy(T) - ((P(yes) * Entropy(Tyes) + P(no) * Entropy(Tno)))$$

$$= 1,571 - \left(\left(\frac{5}{10}\right) * Entropy(Tyes) + \left(\frac{5}{10}\right) * Entropy(Tno)\right)$$

$$Gain(T, parents) = 0,61$$

Hafta sonu Örneği :Bilgi Kazancı

□ Gain(T, money)= ?

- Rich=7 (3 Cinema, 2 Tennis, 1 Shopping, 1 Stay in)
- Poor=3 (3 Cinema)

$$Entropy(T_{rich}) = 1,842$$

$$Gain(T, mone = Entropy(T) - ((P(rich) * Entropy(Trich) + P(poor) * Entropy(Tpoor))$$

$$= 1,571 - \left(\left(\frac{5}{10} \right) Entropy(Trich) + \left(\frac{5}{10} \right) Entropy(Tpoor) \right)$$

$$Gain(T, money) = 0,2816$$

Hafta sonu Örneği :Bilgi Kazancı


- ❑ Hangi özelliğin seçileceğine karar verelim;

$\text{Gain}(T, \text{weather}) = 0,70$

$\text{Gain}(T, \text{parents}) = 0,61$

$\text{Gain}(T, \text{money}) = 0,2816$

- ❑ Weather özelliği en büyük bilgi kazancını sağladığı için ağacın kökünde yer alacak özellik olarak seçilir.
- ❑ Bu özellik en ayırt edici özellik olarak bulunmuş olur.



Hafta sonu Örneği

- 3. Adım: Ağacın çocuk düğümü olan A düğümüne ait alt veri kümesi belirlenir.

Weekend (Example)	Weather	Parents	Money	Decision (Category)
W1	Sunny	Yes	Rich	Cinema
W2	Sunny	No	Rich	Tennis
W10	Sunny	No	Rich	Tennis


- Her alt küme için tekrar bilgi kazancı hesaplanarak en ayırt edici özellik belirlenir.

$$\begin{aligned}\text{Gain}(S_{\text{sunny}}, \text{parents}) &= 0.918 - (|S_{\text{yes}}|/|S|) * \text{Entropy}(S_{\text{yes}}) - (|S_{\text{no}}|/|S|) * \text{Entropy}(S_{\text{no}}) \\ &= 0.918 - (1/3) * 0 - (2/3) * 0 = 0.918\end{aligned}$$

$$\begin{aligned}\text{Gain}(S_{\text{sunny}}, \text{money}) &= 0.918 - (|S_{\text{rich}}|/|S|) * \text{Entropy}(S_{\text{rich}}) - (|S_{\text{poor}}|/|S|) * \text{Entropy}(S_{\text{poor}}) \\ &= 0.918 - (3/3) * 0.918 - (0/3) * 0 = 0.918 - 0.918 = 0\end{aligned}$$


Hafta sonu Örneđi

- ❑ Yeni düğüm için en ayırt edici özellik Parents olarak belirlenmiştir.
- ❑ Bu işlemler her düğüm için aşağıdaki durumlardan biri oluşuncaya kadar devam eder
 - Örneklerin hepsi aynı sınıfa ait
 - Örnekleri bölecek özellik kalmamış
 - Kalan özelliklerin değerini taşıyan örnek yok



Karar Ağaçlarında Aşırı Uyumun Önüne Geçme

- ❑ Eğitim verilerini en iyi sınıflandıracak duruma kadar her dalını derinleştirir.
- ❑ Bu mantıklı bir stratejiyken, veriler arasında gürültü varsa zorluklara sebep olabilir.
- ❑ Gürültü varken, her yaprak saf (pure) olana dek bölünmeye izin vermek, veriyi ezberleyen (overfitting) çok büyük bir karar ağacı oluşmasına neden olabilir.



- ❑ Aşırı uyumda sonuç olarak , eğitim verilerinden bağımsız test verileri ile ölçülen doğruluk önce artar sonra ise azalır.

Aşırı Uyumdan Kaçınmak için Ne Yapmalıyız ?

Budamanın Gerekliliği

- ❑ Budanmış ağaçlar daha kısa ve daha az karmaşık olma eğilimindedirler.
- ❑ Daha kolay anlaşılırlar.
- ❑ Genellikle daha hızlıdır.
- ❑ Test verilerini sınıflamada daha başarılıdır.

Budama (Pruning)

- ❑ Karar ağacı uygulamasında overfitting'i önleyen yöntemler iki gruba ayrılırlar:
 - Pre-pruning (erken budama)
 - Post-pruning (geç budama)
- ❑ Hangi yaklaşım daha geçerlidir?
 - ilki daha direk bir yaklaşım gibi görünürken
 - ikincisi pratikte daha kabul edilir sayılmaktadır.

Erken Budama (Pre-Pruning)


- ❑ Ağacın büyümesini erken durduran yaklaşımlar (eğitim verilerini çok iyi sınıflayan noktaya erişmeden önce)
- ❑ Bir düğüme ulaşan örnek sayısı, eğitim verilerinin belirli bir yüzdesinden daha küçükse o düğüm artık bölünmez.
- ❑ Az sayıda örneğe bağlı olarak alınan kararlar genelleme hatasını artırır.
- ❑ Daha hızlı çözüm.

Geç Budama (Post Pruning)


- ❑ Ağacın veriye oturmasına izin veren ve daha sonra ağacı budayan yaklaşımlar.
- ❑ Karar ağaçlarında uygulanan “greedy” algoritması: her adımda bir düğüm ekler, geriye dönüp başka bir seçenek düşünmez.
- ❑ Bu durumun tek istinası: gereksiz alt ağaçların bulunup budanmasıdır.
- ❑ Daha doğru çözüm.

Ağaç Budama

Büyütülmüş Ağaç



Budanmış Ağaç



Karar Ağacının Avantajları



- ❑ Karar ağacı oluşturmak zahmetsiz
- ❑ Küçük ağaçları yorumlamak kolay
- ❑ Anlaşılabilir kurallar oluşturulabilir
- ❑ Ayrık nitelik değerleri için kullanılabilir



Karar Ağacının Dezavantajları

- ❑ Sürekli nitelik değerlerini tahmin etmekte çok başarılı değil
- ❑ Sınıf sayısı fazla ve öğrenme kümesi örnekleri sayısı az olduğunda model oluşturmada çok başarılı değil.
- ❑ Büyük öğrenme kümeleri için
 - ağaç oluşturma karmaşıklığı fazla,
 - ağaç budama karmaşıklığı fazla

Örnek Çalışmalar (Son 5 yıl)

- ❑ "Ilyas, Hamida; Ali, Sajid; Ponum, Mahvish; Hasan, Osman; Mahmood, Muhammad Tahir; Iftikhar, Mehwish; Malik, Mubasher Hussain; ", **Chronic kidney disease diagnosis using decision tree algorithms**, BMC nephrology, 22, 1, 273, 2021, Springer
- ❑ "Izonin, Ivan; Tkachenko, Roman; Shakhovska, Nataliya; Ilchyshyn, Bohdan; Singh, Krishna Kant; ", **A two-step data normalization approach for improving classification accuracy in the medical diagnosis domain**, Mathematics, 10, 11, 1942, 2022, MDPI
- ❑ "Dinesh, Paidipati; Vickram, AS; Kalyanasundaram, P; ", **Medical image prediction for diagnosis of breast cancer disease comparing the machine learning algorithms: SVM, KNN, logistic regression, random forest and decision tree to measure accuracy**, AIP Conference Proceedings, 2853, 1, 020140, 2024, AIP Publishing LLC
- ❑ "Alves, Marcos Antonio; Castro, Giulia Zanon; Oliveira, Bruno Alberto Soares; Ferreira, Leonardo Augusto; Ramírez, Jaime Arturo; Silva, Rodrigo; Guimarães, Frederico Gadelha; ", **Explaining machine learning based diagnosis of COVID-19 from routine blood tests with decision trees and criteria graphs**, Computers in Biology and Medicine, 132, 104335, 2021, Elsevier
- ❑ "Schönnagel, Lukas; Caffard, Thomas; Zhu, Jiaqi; Tani, Soji; Camino-Willhuber, Gaston; Amini, Dominik A; Haffer, Henryk; Muellner, Maximilian; Guven, Ali E; Chiapparelli, Erika; ", **Decision-making algorithm for the surgical treatment of degenerative lumbar spondylolisthesis of L4/L5**, Spine, 49, 4, 261-268, 2024, LWW
- ❑ "Han, Chang; Liu, Jianghao; Wu, Yijun; Chong, Yuming; Chai, Xiran; Weng, Xisheng; ", **To predict the length of hospital stay after total knee arthroplasty in an orthopedic center in China: the use of machine learning algorithms**, Frontiers in surgery, 8, 606038, 2021, Frontiers Media SA
- ❑ "Sitar, Nejc; Dadgostari, Faraz; Whitaker, Bradley M; McCrory, Bernadette; ", **Evaluation of Decision Tree for predicting Patients' Length of Stay After Arthroplasty Surgical Procedures in the Rural Healthcare**, "2023 Intermountain Engineering, Technology and Computing (IETC)", 209-214, 2023, IEEE